MSE[1] = 0: Το τέλειο *σφάλμα* της Υπερπροσαρμογής

Μία σύγκλιση στα σύνορα Μαθηματικών, Τεχνητής Νοημοσύνης και Επιστημολογίας

r.0.9.5 – 14 Απρ 2026

Δαυίδ Ράδος

Μαθητής Β' Γυμνασίου, Campion School Athens

ORCID: 0009-0000-7937-407X

david.c.rados@gmail.com

ΠΕΡΙΛΗΨΗ

Γιατί η αποστήθιση παλαιών θεμάτων δεν εγγυάται την επιτυχία στις εξετάσεις; Γιατί το ChatGPT δεν απομνημονεύει όλο το περιεχόμενο του διαδικτύου; Η απάντηση και στις δύο ερωτήσεις είναι ίδια: Υπερπροσαρμογή (overfitting). Είναι η παγίδα του να προσαρμοζόμαστε σε υπάρχοντα δεδομένα με τόσο μεγάλη ακρίβεια, με αποτέλεσμα να χάνουμε τα πλεονεκτήματα της γενίκευσης.

Το άρθρο εισάγει την έννοια του overfitting μέσα από ένα παράδειγμα πρόβλεψης ημερήσιων θερμοκρασιών, αναπτύσσει τα μαθηματικά του Μέσου Τετραγωνικού Σφάλματος, του Θεωρήματος Παρεμβολής Lagrange, της Μεροληψίας (Bias), της Διακύμανσης (Variance), και παράλληλα συνδέει αυτές τις ιδέες με το πως τα Μεγάλα Γλωσσικά Μοντέλα (LLMs) εκπαιδεύονται.

Παρουσιάζονται οι ιδέες των Popper, Kolmogorov, Kahneman, Descartes και Αριστοτέλη πάνω στις έννοιες των Πρώτων Αρχών και της Γενίκευσης.

Τέλος, εξηγείται το αποτέλεσμα της μαθηματικής Υπερπροσαρμογής στους αλγορίθμους των social media, που είναι η παραγωγή «βεβαιότητας» χωρίς επιστημονική αλήθεια.

Το άρθρο είναι ανασκοπικού χαρακτήρα και όχι ερευνητικό. Απευθύνεται κυρίως σε μαθητές Γυμνασίου και Λυκείου που έχουν ενδιαφέρον στα Μαθηματικά. Η προσέγγιση είναι διεπιστημονική, συνθέτοντας έννοιες από τα Μαθηματικά, την Τεχνητή Νοημοσύνη και την Επιστημολογία - Θεωρία της Γνώσης.

ΛΕΞΕΙΣ ΚΛΕΙΔΙΑ

Υπερπροσαρμογή, μέσο τετραγωνικό σφάλμα, θεώρημα παρεμβολής Lagrange, μεγάλα γλωσσικά μοντέλα, πρώτες αρχές, μαθηματική γενίκευση, τεχνητή νοημοσύνη, overfitting, test data set, training data set.

ΕΙΣΑΓΩΓΗ - Μετά το διαγώνισμα

«*Μα πως είναι δυνατόν να έγραψα τόσο άσχημα;*» Ο Πάνος δεν μπορούσε να πιστέψει ότι, παρότι είχε διαβάσει για ατελείωτες ώρες, δεν είχε γράψει καλά στο διαγώνισμα. Πριν από κάθε διαγώνισμα, διαβάζει μόνο τα θέματα των προηγούμενων διαγωνισμών, και μαθαίνει όλες τις απαντήσεις απέξω, άπταιστα. Όταν πέφτουν τα θέματα που έχει διαβάσει, είναι ασταμάτητος. Όταν όμως τα θέματα είναι έστω και λίγο διαφορετικά (που συνήθως είναι), «την πατάει».

Εικ.1: Overfitting σε σπιτάκι σκύλου

Από την άλλη, έχουμε την συμμαθήτριά του την Ιωάννα. Διαβάζει τις μισές ώρες και ασχολείται με τις μισές ασκήσεις σε σχέση με τον Πάνο. Όμως, όταν έχει μια απορία, ψάχνει να βρει το «γιατί». Δεν μαθαίνει όλη την ύλη απέξω χωρίς να καταλαβαίνει σε βάθος τι διαβάζει.

Στις προπαρασκευαστικές ασκήσεις, τα πάει καλύτερα ο Πάνος, αλλά στα κανονικά διαγωνίσματα η Ιωάννα τον ξεπερνάει. Δεν τους χωρίζει η προσπάθεια και ο κόπος που καταβάλλουν, τους χωρίζει μια έννοια που οι μαθηματικοί και οι επιστήμονες πληροφορικής ονομάζουν **overfitting**[2] (υπερπροσαρμογή) – μια από τις σημαντικότερες ιδέες της Τεχνητής Νοημοσύνης (AI).

Στην γλώσσα των μαθηματικών, ο Πάνος έχει μηδενικό σφάλμα στο σύνολο δεδομένων προετοιμασίας **(training set)**, δηλαδή στα παλιότερα θέματα, αλλά έχει υψηλό σφάλμα στο δοκιμαστικό σύνολο **(test set)**, δηλαδή στην κανονική εξέταση. Αντίθετα, η Ιωάννα τα πάει χειρότερα στο training set, αλλά πολύ καλύτερα στο πραγματικό διαγώνισμα. Ο Πάνος έχει απομνημονεύσει, ενώ η Ιωάννα έχει **γενικεύσει.**

---

[1] *MSE = Mean Square Error είναι το Μέσο Τετραγωνικό Σφάλμα - ΜΤΣ*

[2] *Στο άρθρο χρησιμοποιείται κυρίως η διεθνής αγγλική ορολογία ή, η ελληνική της απόδοση κατά περίπτωση. Η προσέγγιση αυτή κρίθηκε απαραίτητη καθώς η θεματική περιοχή της Τεχνητής Νοημοσύνης βασίζεται εξ' ολοκλήρου στην αγγλόφωνη βιβλιογραφία.*

Η πολύ σημαντική διαφορά μεταξύ των δύο προσεγγίσεων αποτελεί το κύριο θέμα αυτού του άρθρου.

Τα επόμενα τέσσερα κεφάλαια του άρθρου παρουσιάζουν ένα παράδειγμα με εικονικά δεδομένα ημερήσιας θερμοκρασίας, ώστε οι μαθηματικές έννοιες που θα αναπτυχθούν να είναι πιο εύκολα κατανοητές.

ΤΡΙΑ ΜΑΘΗΜΑΤΙΚΑ ΜΟΝΤΕΛΑ - Θερμοκρασιακές μεταβολές

Ας υποθέσουμε ότι ένας μετεωρολόγος μετράει την θερμοκρασία αέρα 13 φορές κατά την διάρκεια ενός 24ωρου. Ο στόχος του είναι να βρει ένα μαθηματικό μοντέλο που προσαρμόζεται καλύτερα στις μετρήσεις του, ώστε στην συνέχεια να μπορέσει να υπολογίσει τιμές θερμοκρασίας σε ώρες που δεν έχει μετρήσει πρωτογενώς.

Το ζητούμενο μαθηματικό μοντέλο θα είναι ένα **πολυώνυμο**[3] **n-οστού βαθμού** της εξής μορφής:

$$P(x) = a_\nu x^\nu + a_{\nu-1}x^{\nu-1} + a_{\nu-2}x^{\nu-2} + \cdots + a_2x^2 + a_1x + a_0 \qquad (1)$$

Στην εξίσωση (1), το $P(x)$ είναι η προβλεπόμενη θερμοκρασία, το x παρουσιάζει τα δεδομένα εισόδου (ώρες της ημέρας), και οι συντελεστές $a_0, a_1, \dots, a_\nu$ είναι σταθερές που χρησιμοποιούνται για καλύτερη προσαρμογή στα δεδομένα.

Για παράδειγμα, ο συντελεστής a_0 είναι ο σταθερός όρος που ανεβάζει ή κατεβάζει όλη την καμπύλη, ο a_1 ελέγχει την κλίση (πόσο γρήγορα ανεβαίνει ή κατεβαίνει η καμπύλη), ο a_2 ελέγχει την καμπυλότητα (εάν η καμπύλη είναι κυρτή ή κοίλη), και οι λοιποί συντελεστές προσθέτουν ολοένα και πιο λεπτομερείς τοπικές διακυμάνσεις στην καμπύλη.

Όπως θα δούμε παρακάτω, η ανεύρεση αυτών των συντελεστών είναι ουσιαστικά η εκπαίδευση του μαθηματικού μοντέλου.

Η **Μέθοδος των Ελαχίστων Τετραγώνων - ΜΕΤ**[4], όπως εξηγείται στο επόμενο κεφάλαιο, είναι μία αξιόπιστη επιλογή αξιολόγησης του μοντέλου, αφού επιτρέπει να ελαχιστοποιήσουμε το άθροισμα των τετραγώνων των διαφορών (σφαλμάτων) μεταξύ των παρατηρούμενων τιμών και των τιμών που προβλέπονται από το μοντέλο.

Ο μετεωρολόγος δοκιμάζει τρία μαθηματικά μοντέλα, οι γραφικές παραστάσεις των οποίων παρουσιάζονται στην *Εικόνα 2*.

- <u>Πολυώνυμο 1ου βαθμού:</u> Μία ευθεία που δεν μπορεί να αποδώσει τις μεταβολές της θερμοκρασίας. Είναι ένα καλό παράδειγμα **underfitting** (υποπροσαρμογής), το αντίθετο του overfitting. Το πολυώνυμο έχει μόνο δύο συντελεστές: a_0 που ρυθμίζει το ύψος (το Y) και a_1 που ρυθμίζει την κλίση. Είναι προφανές ότι δεν μπορεί να αποδώσει το κυματοειδές μοτίβο της θερμοκρασίας.
- <u>Πολυώνυμο 3ου βαθμού:</u> Μία κυβική καμπύλη με ένα τοπικό μέγιστο και ένα τοπικό ελάχιστο, που αποδίδει την καμπυλόμορφη μεταβολή της θερμοκρασίας αρκετά ικανοποιητικά.
- <u>Πολυώνυμο 12ου βαθμού:</u> Η γραφική παράσταση του πολυωνύμου περνάει από κάθε σημείο μέτρησης. Θα έπρεπε να είναι το πιο κατάλληλο γράφημα συνολικά, όμως δεν είναι. Παρατηρούμε έντονα καμπυλωμένες εξάρσεις μεταξύ σημείων που προβλέπουν παράλογες θερμοκρασίες όπως για παράδειγμα κοντά στην ώρα 01:00[5].
  Όταν το πολυώνυμο κληθεί να προβλέψει θερμοκρασίες εκτός των ωρών μέτρησης, καταρρέει. Είναι ένα καλό παράδειγμα **overfitting**.

Είναι σημαντικό σε αυτό το σημείο να επισημάνουμε ότι τα μοντέλα *underfitting* αποτυγχάνουν παντού και πάντα, αλλά το υψηλό σφάλμα αυτών των μοντέλων είναι **προβλέψιμο**. Ξέρουμε ότι το μοντέλο είναι

---

[3] *Στο παρόν άρθρο οι λέξεις «μοντέλο» και «πολυώνυμο» χρησιμοποιούνται εναλλάξ, αναφερόμενοι ειδικά στο πολυωνυμικό μοντέλο παρεμβολής.*

[4] *Η ΜΕΤ επινοήθηκε ανεξάρτητα από δύο κορυφαίους μαθηματικούς στις αρχές του 19ου αιώνα, με τον Γάλλο Adrien-Marie Legendre να προηγείται στην δημοσίευση (1805), και τον Γερμανό* ***Carl Friedrich Gauss*** *να υποστηρίζει ότι την είχε αναπτύξει ήδη από το 1795, αλλά τη δημοσίευσε επίσημα το 1809 στο έργο του "Theoria motus corporum coelestium".*

[5] *Τα πολυώνυμα Lagrange υψηλού βαθμού είναι γνωστά για τις πολύ μεγάλες εξάρσεις τους (σφάλματα), ειδικά στις άκρες του διαστήματος εφαρμογής. Ο Carl Runge ανακάλυψε αυτό το φαινόμενο (1901) μελετώντας την συνάρτηση:* $f(x) = \frac{1}{1+25x^2}$ *στο διάστημα [-1,1]. Το φαινόμενο Runge είναι ένα κλασικό πρόβλημα της Αριθμητικής Ανάλυσης που εμφανίζεται όταν προσπαθούμε να προσεγγίσουμε μια συνάρτηση χρησιμοποιώντας πολυωνυμική παρεμβολή υψηλού βαθμού.*

κακό. Τα *overfitted* μοντέλα όμως μπορούν να μας εξαπατήσουν αφού φαίνονται τέλεια στα γνωστά δεδομένα, αλλά καταρρέουν στα άγνωστα – το σφάλμα τους είναι **απρόβλεπτο**.

Με απλά λόγια θα μπορούσαμε να πούμε ότι το *underfitting* είναι **γνωστό άγνωστο** – ξέρουμε τι δεν ξέρουμε. Το *overfitting* είναι **άγνωστο άγνωστο** – δεν ξέρουμε ότι δεν ξέρουμε.

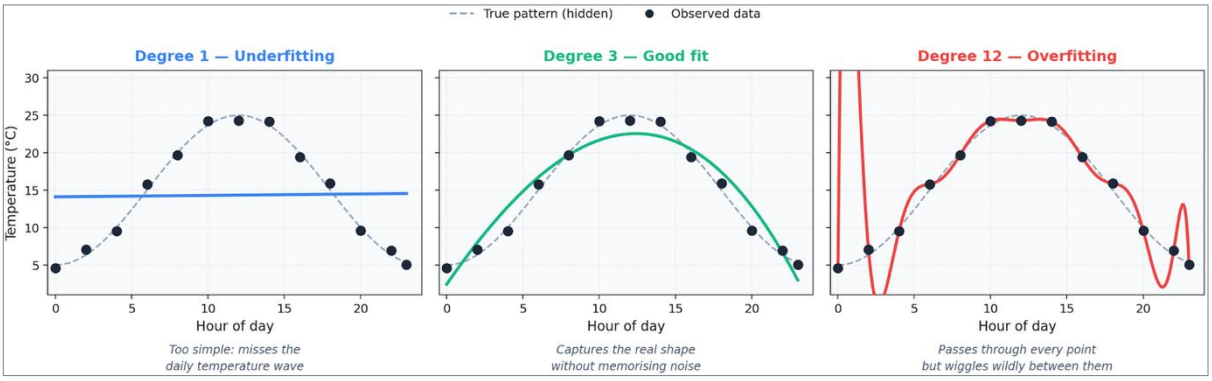

Εικόνα 2: Τρία πολυώνυμα προσαρμοσμένα στις ίδιες 13 θερμοκρασίες. Κοινά δεδομένα εισόδου, διαφορετικά αποτελέσματα.

ΠΟΣΟ ΛΑΘΟΣ ΕΙΝΑΙ ΤΟ ΛΑΘΟΣ - Lagrange & MSE

Για να ποσοτικοποιήσουμε πόσο καλά το κάθε μοντέλο προσαρμόζεται στα δεδομένα, μπορούμε να χρησιμοποιήσουμε το Μέσο Τετραγωνικό Σφάλμα – ΜΤΣ, ή αλλιώς **MSE – Mean Squared Error**. Γενικότερα, για ένα σύνολο δεδομένων n, όπου το καθένα έχει μια μετρημένη τιμή y_i, και μία προβλεπόμενη από το μοντέλο $\hat{y}_i$, το MSE είναι:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \qquad (2)$$

Κάθε όρος $(y_i - \hat{y}_i)^2$ είναι το τετράγωνο υπολοίπου – της διαφοράς μεταξύ της πραγματικής μέτρησης και της πρόβλεψης (βλέπε *Εικόνα 3*).

Υπάρχουν δύο λόγοι που υψώνουμε τις διαφορές στο τετράγωνο. Ο πρώτος είναι ότι υψώνοντας στο τετράγωνο, εξαλείφουμε το πρόσημο της διαφοράς. Ο δεύτερος λόγος είναι για να δώσουμε περισσότερο βάρος σε σημεία μέτρησης που απέχουν σημαντικά από την τιμή που δίνει η εφαρμογή του πολυωνύμου. Αυτή η μέθοδος, η οποία πρακτικά «τιμωρεί» το μοντέλο, αφού η διαφορά Δy υψώνεται στο τετράγωνο, μας οδηγεί σε μία πιθανή βελτίωση του πολυωνύμου, με τους περιορισμούς που θα αναπτύξουμε στην συνέχεια. Η *Εικόνα 3* παρουσιάζει το MSE για το πολυώνυμο 3^{ου} βαθμού.

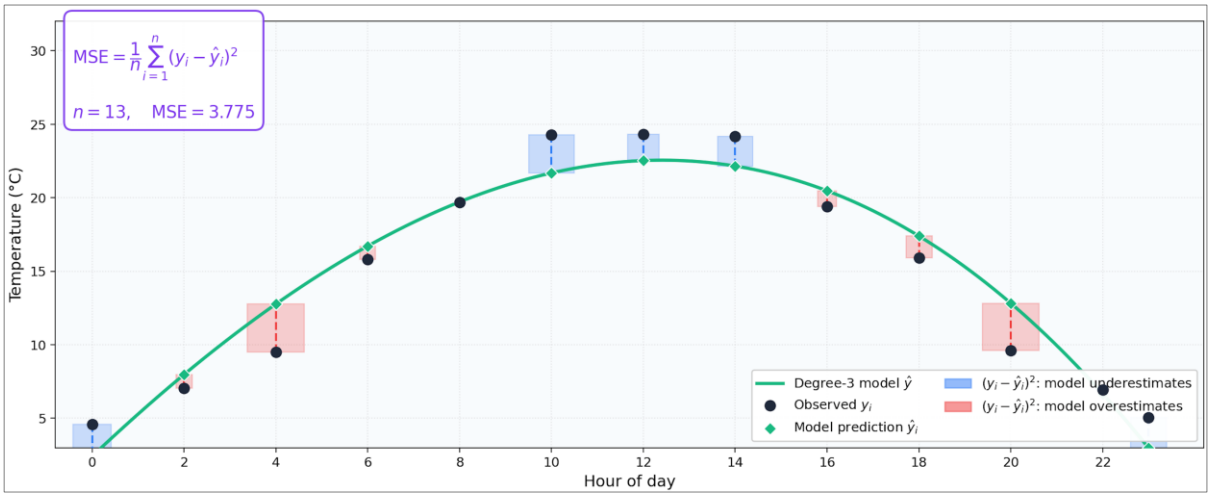

Εικόνα 3: Τετράγωνα υπολοίπων για το πολυώνυμο 3^{ου} βαθμού. Κάθε τετράγωνο έχει εμβαδό ίσο με το τετράγωνο σφάλματος στο σημείο. Το MSE είναι ο μέσος όρος τους.

Τι συμβαίνει όμως με το πολυώνυμο 12^{ου} βαθμού;

Όπως έχουμε προαναφέρει, το πολυώνυμο 12ου βαθμού έχει MSE = 0. Κάθε τετράγωνο υπολοίπου είναι 0. Αυτό δεν είναι σύμπτωση, είναι μαθηματική βεβαιότητα, αφού το πολυώνυμο σχεδιάστηκε για να κάνει ακριβώς αυτό.

Το 1795, ο Ιταλο-Γάλλος μαθηματικός Joseph-Louis Lagrange διατύπωσε το **Θεώρημα Παρεμβολής Lagrange**, –ένα από τα σημαντικά θεωρήματα της Αριθμητικής Ανάλυσης– σύμφωνα με το οποίο, για οποιαδήποτε σημεία δεδομένων *n,* υπάρχει πάντα ένα μοναδικό πολυώνυμο *n* – 1 βαθμού που περνάει ακριβώς από όλα τα σημεία. Δηλαδή που ικανοποιεί την συνθήκη: $L(x_i)=y_i$ για κάθε i=0,1,…,n.

Εικόνα 4: J.L. Lagrange (1736-1813)

Στο δικό μας παράδειγμα, με 13 σημεία μέτρησης, το πολυώνυμο 12ου βαθμού έχει 13 συντελεστές (έναν για κάθε σημείο) που λαμβάνουν τιμές ώστε να αφήσουν MSE = 0. Σύμφωνα με τον Lagrange, για κάθε σημείο δεδομένων *i*, θεωρούμε ένα **Πολυώνυμο Βάσης**[6]:

$$\ell_i(x) = \prod_{\substack{j=1 \\ j\neq i}}^{n} \frac{x - x_j}{x_i - x_j} \qquad (3)^7$$

Αυτό το πολυώνυμο, όπως εύκολα γίνεται αντιληπτό από την εξίσωση (3), έχει την εξής ιδιότητα:
Εάν θέσουμε $x=x_i$, τότε $\ell_i(x_i) = 1$. Εάν θέσουμε οποιοδήποτε άλλο x_j (όπου $j \neq i$), τότε $\ell_i(x_j) = 0$.

Το τελικό πολυώνυμο παρεμβολής είναι το άθροισμα των πολυώνυμων βάσης πολλαπλασιαζόμενων με το αντίστοιχο y_i:

$$L(x) = \sum_{i=1}^{n} y_i \ell_i(x) \qquad (4)$$

Η πολυωνυμική παρεμβολή του Lagrange θα έβγαζε MSE=0 για οποιεσδήποτε 13 τιμές θερμοκρασίας, χωρίς να μπορεί να καταλάβει εάν υπάρχει κάποιο μοτίβο στα δεδομένα, απλώς λύνοντας κάθε φορά 13 εξισώσεις με 13 αγνώστους. Είναι λοιπόν κατανοητό ότι το πολυώνυμο 12ου βαθμού έχει απλώς «**απομνημονεύσει**» κάθε μέτρηση που του έχει δοθεί. Η αξία του στην πρόβλεψη είναι μηδενική, όπως ακριβώς και το MSE=0.

ΕΚΠΑΙΔΕΥΟΝΤΑΣ ΤΟ ΜΑΘΗΜΑΤΙΚΟ ΜΟΝΤΕΛΟ

Μέχρι τώρα είδαμε ότι στο παράδειγμα των θερμοκρασιών, τα πολυώνυμα 1ου βαθμού και 12ου βαθμού έχουν ουσιαστικά μηδενική αξία, ενώ αντιθέτως το πολυώνυμο 3ου βαθμού λειτουργεί αρκετά ικανοποιητικά.

Εύλογα λοιπόν προκύπτει μια σειρά ερωτημάτων: Μήπως ένα πολυώνυμο 4ου ή 5ου βαθμού λειτουργεί καλύτερα; Ποιος βαθμός πολυωνύμου είναι αυτός που ελαχιστοποιεί το MSE, αλλά ταυτόχρονα εκπαιδεύει καλύτερα το μοντέλο;

Για να προσεγγίσουμε την απάντηση στα παραπάνω ερωτήματα, θα πρέπει να ελέγξουμε το μοντέλο με καινούργια δεδομένα που δεν έχει ξαναδεί. Για να το πετύχουμε αυτό μπορούμε να χωρίσουμε τα δεδομένα σε δύο υποσύνολα: στα δεδομένα εκπαίδευσης – **training set**, και στα δεδομένα ελέγχου – **test set**. Από τις 13 μετρήσεις θερμοκρασίας που έχουμε παίρνουμε 10 από αυτές (περίπου το 80%) για να αποτελέσουν το training set, και τις υπόλοιπες 3 τις χρησιμοποιούμε για το test set.

Τώρα, μπορούμε να υπολογίσουμε δύο διαφορετικές τιμές λάθους: $MSE_{train}\ vs.\ MSE_{test}$. Η *Εικόνα 5*, παρουσιάζει τα MSE για τα δύο υποσύνολα όταν αυξάνουμε τον βαθμό του πολυωνύμου από το 1 στο 10.

---

[6] *Στην εξίσωση (3), ο αριθμητής είναι το γινόμενο των όρων $(x-x_0)(x-x_1)\ldots(x-x_n)$, εξαιρώντας τον όρο $(x-x_i)$. Έτσι εξασφαλίζεται ότι το πολυώνυμο θα μηδενιστεί σε όλα τα δεδομένα σημεία x_j, εκτός από το x_i. Ο παρονομαστής είναι το ίδιο ακριβώς γινόμενο με τον αριθμητή, με την διαφορά ότι στην θέση του x έχει τοποθετηθεί η σταθερή τιμή x_i. Έτσι εξασφαλίζεται ότι στο σημείο x_i το αποτέλεσμα θα είναι 1.*

[7] *Το κεφαλαίο **Π** στα μαθηματικά είναι το σύμβολο του γινομένου. Χρησιμοποιείται για να αναπαραστήσει με συντομογραφία το γινόμενο μιας ακολουθίας όρων.*

Από την μπλε γραμμή (MSE_{train}), παρατηρούμε πως περισσότεροι παράμετροι σημαίνουν μικρότερο MSE, που στον 10ο πολυωνυμικό βαθμό σχεδόν μηδενίζεται ($MSE_{train} = 0$).

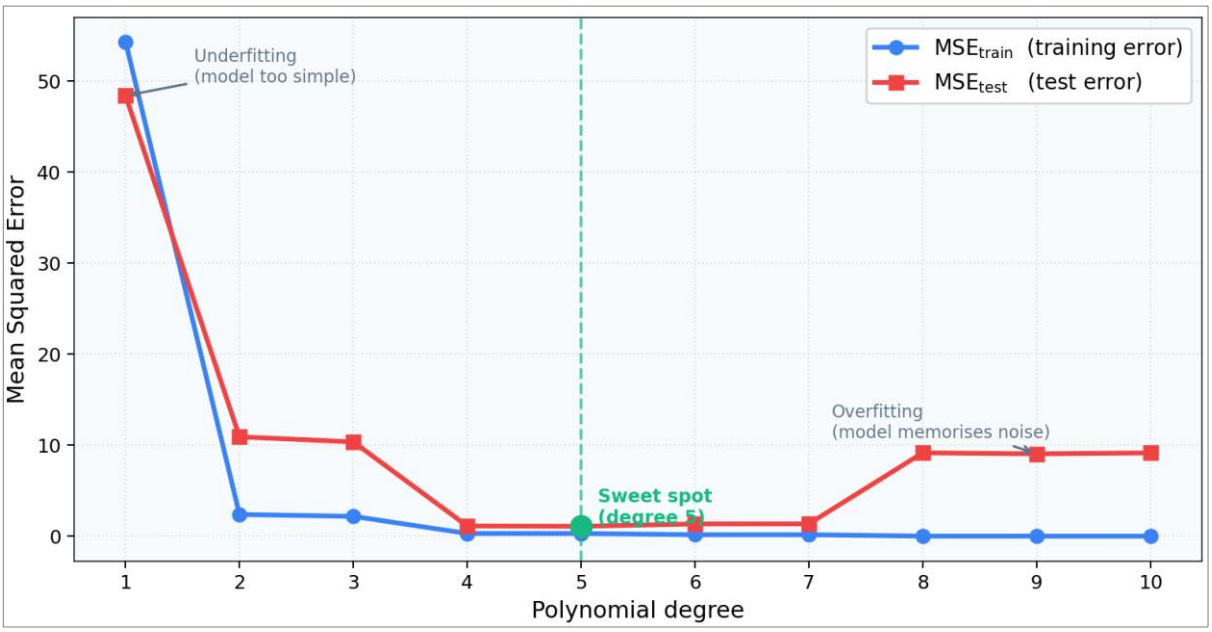

Εικόνα 5: Όσο ο βαθμός του πολυωνύμου αυξάνει, το MSE_{train} πάντα μειώνεται (μπλε). Αντιθέτως, το MSE_{test} φτάνει σε μια χαμηλή τιμή, πριν αρχίσει να ανεβαίνει.

Αντιθέτως, παρατηρούμε μια διαφορετική συμπεριφορά στην κόκκινη γραμμή (MSE_{test}). Σε χαμηλούς βαθμούς πολυωνύμου, το MSE_{test} είναι πολύ ψηλά. Όσο ο βαθμός όμως ανεβαίνει, το MSE_{test} πέφτει, και στον 5ο βαθμό φτάνει στο χαμηλότερο του σημείο. Στην συνέχεια όμως, όσο ανεβαίνει ο βαθμός πολυωνύμου, το MSE_{test} αρχίζει να ανεβαίνει και αυτό. Αυτή η απόκλιση είναι χαρακτηριστική του *overfitting*. Για παράδειγμα, για πολυώνυμα 8ου βαθμού και πάνω:

$$MSE_{train} \approx 0 \; \alpha\lambda\lambda\acute{\alpha} \; MSE_{test} \gg 0. \qquad (5)$$ [8]

Συμπερασματικά λοιπόν διαπιστώνουμε από το παράδειγμά μας ότι: Ένα μοντέλο με $MSE_{train} = 0$ έχει **απομνημονεύσει**, ενώ ένα μοντέλο με χαμηλό MSE_{test} έχει **κατανοήσει** και δίνει αξία στην πρόβλεψη.

BIAS & VARIANCE - Γιατί τα μοντέλα αποτυγχάνουν

Κάθε αποτυχία ενός μαθηματικού μοντέλου ταξινομείται σε δύο κατηγορίες, οι οποίες «οδηγούν» το μοντέλο σε αντίθετες κατευθύνσεις. Αυτές είναι η Μεροληψία – **Bias** και η Διακύμανση – **Variance**.

Το **Bias** είναι το σφάλμα που προκύπτει από ένα υπεραπλουστευμένο μοντέλο. Ας γυρίσουμε πίσω στην ευθεία γραμμή 1ου πολυωνυμικού βαθμού στην *Εικόνα 2*. Το μοντέλο υποθέτει ότι η θερμοκρασία μεταβάλλεται γραμμικά. Αυτή η υπόθεση είναι προφανώς λανθασμένη, και καμία ποσότητα δεδομένων δεν μπορεί να βοηθήσει στην διόρθωσή της – το μοντέλο είναι από μόνο του ανίκανο να αποδώσει την καμπυλόμορφη κατανομή των θερμοκρασιών. Συνοπτικά θα λέγαμε ότι το *bias* μετρά την απόκλιση μεταξύ της μέσης πρόβλεψης του μοντέλου και της πραγματικής τιμής:

$$Bias^2 = \left(\bar{\hat{y}} - y\right)^2 \qquad (6)$$

Όπου $\bar{\hat{y}}$ είναι η μέση πρόβλεψη του μοντέλου από πολλά διαφορετικά *training sets* και y είναι η πραγματική τιμή. Ένα μοντέλο με υψηλό bias κάνει σταθερά το ίδιο λάθος. Αυτό είναι το **underfitting**.

Το **Variance** από την άλλη, είναι το αντίθετο σφάλμα. Προκύπτει από ένα πολύ «ευαίσθητο» μοντέλο, όπως για παράδειγμα το πολυώνυμο 12ου βαθμού στην *Εικόνα 2*. Το μοντέλο προσπαθεί να περάσει από κάθε σημείο, και εάν επαναλάβουμε το πείραμα μία διαφορετική ημέρα, με μικρές αλλαγές στις μετρήσεις, η ευθεία 1ου βαθμού δεν θα άλλαζε σχεδόν καθόλου, ενώ αντιθέτως, η καμπύλη 12ου βαθμού θα έμοιαζε εντελώς διαφορετική. Το variance, μετρά ακριβώς αυτή την αστάθεια:

[8] *≈ σημαίνει: προσεγγιστικά ίσο με. ≫ σημαίνει πολύ μεγαλύτερο από.*

$$Variance = \mathbb{E}\left[\left(\hat{y} - \bar{\hat{y}}\right)^2\right] \qquad (7)$$[9]

Ένα μοντέλο με υψηλό variance δεν κάνει σταθερά λάθη, κάνει απρόβλεπτα λάθη. Αυτό είναι το **overfitting**.

Οι δύο τύποι σφαλμάτων συνδέονται με μια ταυτότητα, η οποία δίνει το συνολικό σφάλμα πρόβλεψης κάθε μοντέλου και αναλύεται ως εξής:

$$Total\ Error = Bias^2 + Variance + Noise \qquad (8)$$[10]

Η εξίσωση (8) στην βιβλιογραφία ονομάζεται **Bias-Variance Tradeoff Theorem** (Θεώρημα Αντιστάθμισης Μεροληψίας – Διακύμανσης) και είναι μία από τις βασικές εξισώσεις της μηχανικής μάθησης – **machine learning**. Η απόδειξη της εξίσωσης (8) παρουσιάζεται στο **Παράρτημα** του άρθρου, ώστε να μην διακοπεί η ροή του κειμένου.

Η γραφική απεικόνιση της εξίσωσης παρουσιάζεται στην *Εικόνα 6* στην οποία παρατηρούμε ότι:

– Όσο ο βαθμός του πολυωνύμου αυξάνει, το *bias* μικραίνει και τείνει να μηδενιστεί, ενώ αντίστροφα το *variance* αυξάνεται εκθετικά.

– Το total error είναι καμπύλη μορφής U, όπου το κατώτατο σημείο της είναι το σημείο που καταδεικνύει τον προτιμητέο βαθμό του πολυωνύμου.

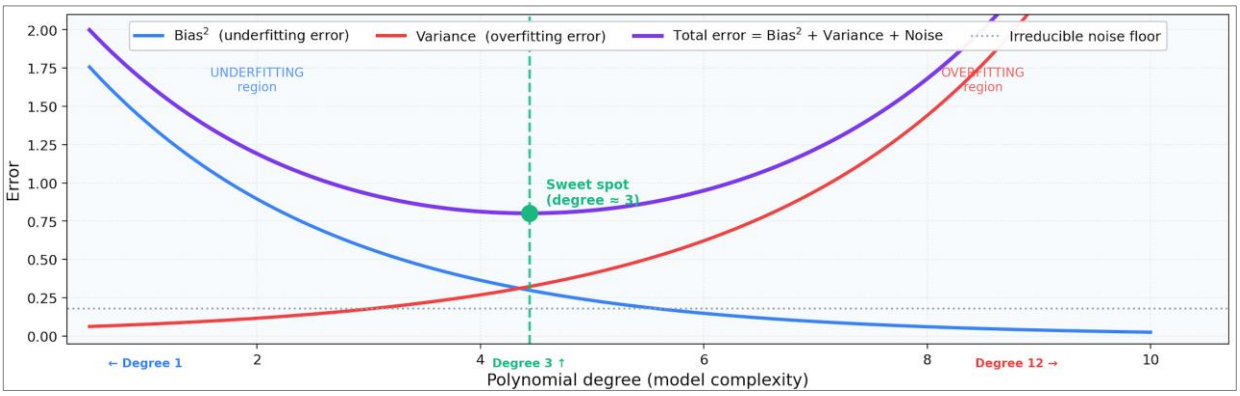

Εικόνα 6: Bias - Variance Tradeoff. Παρουσιάζονται οι δύο κατηγορίες σφαλμάτων, το συνολικό σφάλμα και το sweet spot που πρακτικά δείχνει τον ιδανικό πολυωνυμικό βαθμό του μοντέλου (βλ. σχετικά και την Εικόνα 5).

Το θεώρημα αποδεικνύει ότι η προσπάθεια μείωσης του *bias* αυξάνει αναπόφευκτα το *variance*, και αντίστροφα. Δεν υπάρχει μοντέλο με μηδενικό *bias* και μηδενικό *variance* ταυτόχρονα – εκτός και εάν τα δεδομένα δεν περιέχουν *irreducible noise*, κάτι που στην πραγματικότητα δεν συμβαίνει ποτέ.

ΤΑ LLMs ΔΕΝ (πρέπει να) ΑΠΟΜΝΗΜΟΝΕΥΟΥΝ

Το ChatGPT-v3 είχε περίπου 175 δις παραμέτρους. Πολύ υπεραπλουστευμένα μπορούμε να τις σκεφτούμε σαν τους συντελεστές του πολυωνύμου του παραδείγματός μας.

Το training set αποτελούνταν περίπου από 300 δις ***tokens***[11].

Είναι προφανές ότι 175 δις παράμετροι δεν μπορούν να αποθηκεύσουν 300 δις *tokens*.

Αυτό που μπορούν να κάνουν όμως είναι να ενσωματώσουν την στατιστική δομή της γλώσσας, όπως για παράδειγμα: ποιες λέξεις ακολουθούν μετά από κάποιες άλλες, ποιο είναι το γνωστικό περιβάλλον, και ποια είναι τα θέματα ενδιαφέροντος.

---

[9] *Το σύμβολο* $\mathbb{E}$ *ονομάζεται* ***expected value*** *(μαθηματική προσδοκία) και εκφράζει την μέση αναμενόμενη τιμή σε πολλές επαναλήψεις σετ μετρήσεων. Με άλλα λόγια εκφράζει τον μέσο όρο των αποτελεσμάτων του μοντέλου, μετρώντας πόσο «νευρικές» είναι οι προβλέψεις του απέναντι σε μικρές διακυμάνσεις των δεδομένων.*

[10] *Το Noise αναφέρεται στον μη αναγώγιμο θόρυβο –* ***Irreducible Noise****, που είναι το σφάλμα που κανένα μοντέλο δεν μπορεί να εξαλείψει. Στο παράδειγμά μας, ακόμη και το πιο πλήρες μοντέλο αδυνατεί να προβλέψει την ακριβή θερμοκρασία, αφού για παράδειγμα η σκιά ενός σύννεφου μπορεί να την επηρεάσει απρόβλεπτα. Με άλλα λόγια είναι το κατώτατο όριο κάθε πρόβλεψης.*

[11] *Token είναι η βασική μονάδα κειμένου που επεξεργάζεται ένα γλωσσικό μοντέλο. Μπορεί να είναι ένας χαρακτήρας, τμήμα λέξης, ή ολόκληρη λέξη. Κατά μέσο όρο, ένα token αντιστοιχεί στα τρία τέταρτα μιας αγγλικής λέξης.*

Οι παράμετροι[12] ενσωματώνουν όχι τις προτάσεις που υπάρχουν στις διάφορες πηγές του διαδικτύου, αλλά τους κανόνες που γενούν τις προτάσεις. Όπως ακριβώς και η Ιωάννα που δεν απομνημονεύει παλαιά θέματα διαγωνισμών, αλλά προσπαθεί να καταλάβει την λογική που κρύβεται από πίσω.

Παρόλα αυτά, ένα μοντέλο με 175 δις παραμέτρους υπερπροσαρμόζει. Για να λύσουν αυτό το πρόβλημα, οι μαθηματικοί και μηχανικοί του ChatGPT χρησιμοποίησαν τρία εργαλεία:

- **Regularisation** (κανονικοποίηση / ομαλοποίηση). Κατά την διάρκεια της εκπαίδευσης του το μοντέλο «τιμωρείται» όχι μόνο όταν κάνει σφάλματα στις προβλέψεις, αλλά και όταν στηρίζεται πάρα πολύ σε ένα συγκεκριμένο μοτίβο. Με απλά λόγια, είναι σαν τον καθηγητή που λέει στους μαθητές του «*θα χάσετε βαθμούς εάν η απάντησή σας είναι μεγαλύτερη από μία σελίδα*.» Αυτή η προτροπή του καθηγητή υποχρεώνει τον μαθητή να βρει την ουσία της απάντησης, αντί να γράψει ότι έχει αποστηθίσει.
- **Test set (Validation set)**. Με το test set, παρακολουθείται η γενίκευση κατά την διάρκεια της εκπαίδευσης του μοντέλου. Όταν το MSE_{train} μειώνεται, και ταυτόχρονα το MSE_{test} αυξάνεται, τότε έχει αρχίσει το overfitting.
- **Early stopping**. Η εκπαίδευση του μοντέλου σταματάει όταν το MSE_{test} φτάσει στην ελάχιστη τιμή.

Εντροπία[13], σήμα και θόρυβος – τι πραγματικά μαθαίνουν τα LLMs

Η **εντροπία** είναι μια λέξη από τη φυσική που ο Αμερικανός μαθηματικός **Claude Shannon** δανείστηκε για να περιγράψει πόσο απρόβλεπτο είναι ένα μήνυμα, στο θεμελιώδες έργο του για την επιστήμη της Πληροφορίας: *A Mathematical Theory of Communication (1948).* Ο Shannon διέκρινε το **σήμα**, την πραγματική πληροφορία που θέλεις να μεταδώσεις, από τον **θόρυβο,** δηλαδή τις τυχαίες διακυμάνσεις που δεν σημαίνουν τίποτα. Ένα *overfitted* μοντέλο δεν καταφέρνει να κάνει αυτή τη διάκριση: μεταχειρίζεται τον θόρυβο σαν να ήταν σήμα, και τον αποθηκεύει με την ίδια σοβαρότητα.

Αυτό συνδέεται άμεσα με τα LLMs. Το ChatGPT εκπαιδεύεται να βρίσκει τη **χαμηλή εντροπία μέσα στα δεδομένα**, δηλαδή τη βαθύτερη δομή της γλώσσας πίσω από εκατοντάδες δισεκατομμύρια λέξεις. Αν υπερπροσαρμοστεί, αποθηκεύει και τον θόρυβο, δηλαδή τις τυχαίες, μη επαναλαμβανόμενες λεπτομέρειες και χάνει τη γενική δομή.

Overfitting & context drift στο chat - Το κρυφό πρόβλημα των LLMs

Υπάρχει μια λιγότερο γνωστή μορφή *overfitting* που εμφανίζεται κατά τη χρήση των *LLMs* σε μακρές συνομιλίες (*chats*) που κάνουν οι χρήστες των μοντέλων. Τα μοντέλα αυτά δεν «θυμούνται» με την ανθρώπινη έννοια, αλλά διαβάζουν ολόκληρο το ιστορικό του *chat* κάθε φορά που παράγουν μια απάντηση. Όταν το chat γίνεται πολύ μεγάλο, συμβαίνουν τρία πράγματα:

- Πρώτον, τα πρώτα μηνύματα και οι αρχικές οδηγίες, λαμβάνουν ολοένα λιγότερη «προσοχή» και σταδιακά «ξεχνιούνται».
- Δεύτερον, αν το μοντέλο έκανε ένα λάθος στη μέση της συνομιλίας, αυτό το λάθος εισέρχεται στο τρέχον περιεχόμενο (context) και **ανατροφοδοτεί** τις επόμενες απαντήσεις, δηλαδή κάνει κυριολεκτικά *overfitting* στον θόρυβο – σφάλμα της συνομιλίας.
- Τρίτον, το μοντέλο προσαρμόζεται σταδιακά στο πιο πρόσφατο τμήμα της συνομιλίας, χάνοντας τη «μεγάλη εικόνα». Αυτό ονομάζεται **context drift**.

Η λύση στο πρόβλημα; Νέο chat για κάθε νέα ενότητα, επανάληψη των βασικών οδηγιών, και κριτική αξιολόγηση των απαντήσεων. Το *test set* σε αυτή την περίπτωση είναι η κρίση του ίδιου του χρήστη.

---

[12] *Τα γλωσσικά μοντέλα LLMs δεν χρησιμοποιούν πολυώνυμα - αυτό είναι μια απλοποίηση του άρθρου. Τα LLMs βασίζονται στη **Γραμμική Άλγεβρα**: οι παράμετροί τους είναι στοιχεία πινάκων βαρών (weight matrices) υψηλών διαστάσεων. Κάθε token μετατρέπεται σε **διάνυσμα** (vector) εκατοντάδων ή χιλιάδων διαστάσεων, και η εκπαίδευση του μοντέλου συνίσταται στη βελτιστοποίηση εκατοντάδων τέτοιων πινάκων μέσω πράξεων πολλαπλασιασμού και μετασχηματισμού. Το overfitting σε αυτό το πλαίσιο σημαίνει ότι οι πίνακες βαρών έχουν προσαρμοστεί υπερβολικά στα δεδομένα εκπαίδευσης, χάνοντας την ικανότητα γενίκευσης — ακριβώς όπως το πολυώνυμο 12ου βαθμού του παραδείγματός μας.*

[13] *Η εντροπία παρότι είναι μία έννοια που ο Shannon δανείστηκε από την Φυσική, μετράει την μέση αβεβαιότητα μιας πηγής πληροφορίας. Όσο πιο απρόβλεπτα είναι τα δεδομένα, τόσο υψηλότερη η εντροπία τους. Για παράδειγμα εάν ήδη ξέρεις τι θα πει κάποιος, το μήνυμά του έχει χαμηλή εντροπία, δηλαδή λίγη πραγματική πληροφορία. Αν δεν έχεις ιδέα τι θα πει, έχει υψηλή εντροπία, πολλή πληροφορία.*

ΕΝΑ ΜΟΝΤΕΛΟ ΠΟΥ ΕΞΗΓΕΙ ΤΑ ΠΑΝΤΑ, ΔΕΝ ΕΧΕΙ ΚΑΤΑΝΟΗΣΕΙ ΤΙΠΟΤΑ

Τον 14ο αιώνα, ο **William του Ockham** υποστήριξε ότι «*όταν δύο εξηγήσεις ταιριάζουν εξίσου καλά στα ίδια δεδομένα, πρέπει να προτιμούμε την απλούστερη, αυτή που έχει τις λιγότερες παραδοχές*».

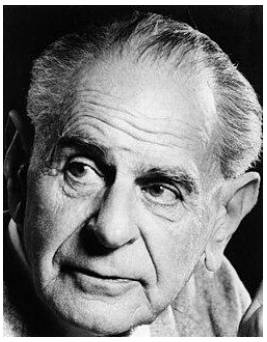

Εικόνα 7: Karl Popper (1902-1994)

Αυτή η ρήση είναι γνωστή σαν το **Occam's razor** (ξυράφι του Occam), το οποίο «ξυρίζει» όλες τις άχρηστες λεπτομέρειες ή παραδοχές από μία θεωρία.

Ο **Karl Popper** το 1934 υποστήριξε ότι μια καλή θεωρία δεν είναι αυτή που εξηγεί τα πάντα – είναι αυτή που **αποκλείει** κάτι. Με απλά λόγια, μια θεωρία συμβατή με κάθε παρατήρηση δεν ρισκάρει τίποτε, δεν δεσμεύεται σε τίποτε, και δεν μας διδάσκει τίποτε. Το ονόμασε **falsifiability** – διαψευσιμότητα, που σημαίνει ότι μια θεωρία αποκτά επιστημονική αξιοπιστία κάνοντας προβλέψεις, που θα πρέπει να μπορούν να αποδειχθούν λανθασμένες – εάν είναι λανθασμένες. Το πολυώνυμο 12ου βαθμού του παραδείγματός μας προσαρμόζεται πάντα και απόλυτα σε οποιουσδήποτε 13 αριθμούς από τον σχεδιασμό του. Είναι **αδιάψευστο**.

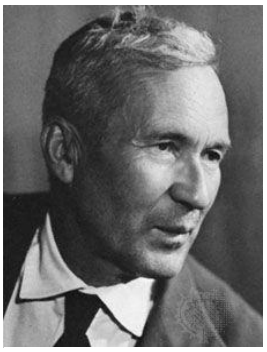

Εικόνα 8: Andrey Kolmogorov (1903-1987)

Την δεκαετία του 1960, ο μεγάλος μαθηματικός και ένας από τους θεμελιωτές της Θεωρίας της Αλγοριθμικής Πληροφορίας **Andrey Kolmogorov** έθεσε μια φαινομενικά απλή ερώτηση: «*υπάρχει αντικειμενικός τρόπος να μετρήσουμε πόσο περίπλοκο είναι ένα σύνολο δεδομένων;*» Η απάντησή του ήταν κομψή: όρισε την πολυπλοκότητα ενός συνόλου δεδομένων ως το μήκος του **συντομότερου προγράμματος** που το παράγει. Εάν το εφαρμόσουμε αυτό στο παράδειγμά μας, η ημερήσια θερμοκρασία ακολουθεί μία ημιτονοειδή μορφή που περιγράφεται από λίγες παραμέτρους. Αντίθετα για να αναπαράγουμε το πολυώνυμο 12ου βαθμού χρειαζόμαστε 13 συντελεστές, χωρίς καμία εσωτερική λογική, με υψηλή πολυπλοκότητα Kolmogorov.

Ο διάσημος ψυχολόγος και κάτοχος Νόμπελ Οικονομικών το 2002 **Daniel Kahneman**, απέδειξε ότι η ανθρώπινη κρίση υποφέρει από τα ίδια προβλήματα που πραγματεύεται το άρθρο μας. Στο διάσημο βιβλίο του **Thinking Fast and Slow** (2011), διακρίνει δύο τρόπους σκέψης. Το **Σύστημα 1**, που είναι γρήγορο και διαισθητικό. Είναι ουσιαστικά ένα μοντέλο υψηλής διακύμανσης που υπερπροσαρμόζεται σε παραστάσεις και το αποκαλεί «ένστικτο». Το **Σύστημα 2**, που είναι αργό, αναλυτικό και συνειδητό, και που εφαρμόζει *κανονικοποίηση*, και *ρύθμιση* στις αντιδράσεις του Συστήματος 1.

Είναι εύλογο να αναρωτηθούμε: Τι είναι αυτό που συνδέει έναν Άγγλο μοναχό του μεσαίωνα, έναν Αυστριακό φιλόσοφο, έναν Σοβιετικό μαθηματικό και έναν Ισραηλινό ψυχολόγο; Κανένας τους δεν είχε γράψει ούτε μία γραμμή από κώδικα, κανένας τους δεν είχε προσαρμόσει πολυώνυμα σε μετρήσεις θερμοκρασίας, κανένας τους δεν είχε εκπαιδεύσει νευρωνικά δίκτυα[14]. Και όμως, ο καθένας δουλεύοντας ανεξάρτητα, στην δική του επιστήμη και στην δική του εποχή, κατέληξε στο ίδιο συμπέρασμα.

4 στοχαστές, 7 αιώνες, 1 ιδέα: **Ένα μοντέλο που εξηγεί τα πάντα δεν έχει κατανοήσει τίποτα**.

OVERFITTING ΠΕΡΑ ΑΠΟ ΤΗΝ ΜΗΧΑΝΗ – Βεβαιότητα χωρίς Επιστημονική Αλήθεια

Μέχρι τώρα μιλήσαμε για *overfitting* σε πολυώνυμα και νευρωνικά δίκτυα. Αλλά η ίδια παγίδα, η μη σωστή αντιστάθμιση Bias και Variance, εμφανίζεται παντού γύρω μας. Ας δούμε τι συμβαίνει όταν οι αλγόριθμοι και τα μοντέλα εσκεμμένα υπερπροσαρμόζουν.

Θεωρίες συνωμοσίας

Φανταστείτε κάποιον που πιστεύει ότι η Γη είναι επίπεδη. Του δείχνετε φωτογραφίες από διαστημικές αποστολές. Απαντά: *«οι φωτογραφίες είναι ψεύτικες, τις έφτιαξε η NASA»*. Του δείχνετε μαθηματικές αποδείξεις. Απαντά: *«τα μαθηματικά είναι λανθασμένα»*. Του δείχνετε τον καμπυλωμένο ορίζοντα στην ανοιχτή θάλασσα. Απαντά: *«αυτό είναι ψευδαίσθηση λόγω της ατμόσφαιρας»*.

[14] *Τα τεχνητά νευρωνικά δίκτυα είναι υπολογιστικά μοντέλα μηχανικής μάθησης, εμπνευσμένα από τη δομή του ανθρώπινου εγκεφάλου. Αποτελούνται από διασυνδεδεμένους κόμβους (τεχνητούς νευρώνες), και επεξεργάζονται δεδομένα για την επίλυση σύνθετων προβλημάτων (π.χ. αναγνώριση προτύπων), μαθαίνοντας να βελτιώνουν τις αποφάσεις τους μέσα από την εμπειρία και τα λάθη τους.*

Το νοητικό του μοντέλο έχει τόσο *Variance* — τόση ευελιξία να ενσωματώνει κάθε νέο αντίθετο δεδομένο ως επιπλέον παράμετρο — ώστε να προσαρμόζεται τέλεια σε οτιδήποτε. Έχει $MSE_{train}=0$.

Η δομή σχηματισμού του νοητικού του μοντέλου είναι πάντα η ίδια. Ξεκινά με μια απλή αφήγηση, δηλαδή με χαμηλό βαθμός πολυωνύμου. Όταν εμφανίζονται **αντιφατικά δεδομένα**, αντί να απορρίψει την θεωρία, **προσθέτει νέες παράμετροι** στο πολυώνυμο, νέους «ενόχους», νέα στρώματα της συνωμοσίας. Ο πολυωνυμικός βαθμός ανεβαίνει και βεβαίως δεν τον ενδιαφέρει καθόλου ότι το μοντέλο του είναι αδιάψευστο κατά *Popper* και επομένως άχρηστο επιστημονικά. Δεν μπορεί να αντιληφθεί ότι η επιστημονική εξήγηση έχει χαμηλή πολυπλοκότητα *Kolmogorov,* ότι είναι δηλαδή ένα πολύ λιτό και σύντομο πρόγραμμα: *«η Γη είναι σφαιρική γιατί η βαρύτητα δρα ισότροπα»*.

Social media — ο αλγόριθμος ως μηχανή overfitting

Οι αλγόριθμοι του *TikTok*, του *YouTube* και του *Instagram* εκπαιδεύονται να μεγιστοποιούν την αλληλεπίδραση (engagement) με τον χρήστη. Αυτό είναι το training set τους. Το test set, δηλαδή η μακροπρόθεσμη ευημερία του χρήστη, και η ποιότητα του δημόσιου διαλόγου δεν μετριέται ποτέ. Το αποτέλεσμα είναι το **υψηλό variance,** αφού ο αλγόριθμος προσαρμόζεται υπερβολικά στις στιγμιαίες προτιμήσεις κάθε χρήστη δημιουργώντας *echo chambers*, και φυσικά **υψηλό bias**, αφού ο χρήστης λαμβάνει πάντα το ίδιο είδος περιεχομένου, στερούμενος κάθε αντίθετης άποψης.

Όπως ο Αλέξης, που μελετά αποκλειστικά παλιά θέματα, ο αλγόριθμος σταματά να σου δείχνει νέες πληροφορίες. Σου δείχνει μόνο αυτές για τις οποίες έχει εκπαιδευτεί ότι θα αντιδράσεις. Το αποτέλεσμα: **Ο κόσμος σου να γίνεται ολοένα πιο μικρός και ολοένα πιο βέβαιος**.

Η σύνδεση με τον Kahneman είναι μάλλον προφανής: ο αλγόριθμος τροφοδοτεί αποκλειστικά το Σύστημα 1, το οποίο έχει υψηλό *variance*, είναι γρήγορο και συναισθηματικό, παρακάμπτοντας το Σύστημα 2, δηλαδή την κανονικοποίηση και ρύθμιση του προμετωπιαίου εγκεφάλου.

Το overfitting δεν είναι μόνο ένα πρόβλημα των μαθηματικών και της πληροφορικής. Είναι ο τρόπος με τον οποίο ο σύγχρονος κόσμος παράγει **βεβαιότητα χωρίς αλήθεια,** εμπιστευόμενος μόνο το ανατροφοδοτούμενο *training set*.

ΣΥΜΠΕΡΑΣΜΑ: *αἱ ἀρχαί*

Ξεκινήσαμε με τον Πάνο και την Ιωάννα. Ο Πάνος απομνημόνευσε μόνο παλιά θέματα και είχε τέλεια βαθμολογία στο *training set*. Η Ιωάννα κατανόησε το *γιατί*, έκανε περισσότερα λάθη στις προσομοιώσεις θεμάτων, αλλά κέρδισε στο πραγματικό διαγώνισμα.

Στην συνέχεια, ο μετεωρολόγος δοκίμασε μια σειρά από μοντέλα στις μετρήσεις του. Ο Lagrange του εγγυήθηκε το *MSE=0*, αλλά το *bias* και το *variance* του μοντέλου του τον βεβαίωσαν ότι αυτό δεν είναι η λύση. Ο Ockham, ο Popper, ο Kolmogorov και ο Kahneman είπαν το ίδιο πράγμα: η τέλεια προσαρμογή στα ήδη υπάρχοντα δεδομένα δεν είναι κατανόηση – είναι απουσία κατανόησης.

Οι παραπάνω στοχαστές περιέγραψαν την παγίδα της υπερπροσαρμογής από διαφορετικές οπτικές, αλλά ήταν ο Γάλλος φιλόσοφος **René Descartes** στο έργο του *Discours de la méthode (1637),* που πρότεινε να αμφισβητούμε τα πάντα μέχρι να φτάσουμε στις **αναγώγιμες πρώτες αρχές**, και μόνο από εκεί να οικοδομούμε προς τα πάνω.

Ο Descartes αντί να αναρωτηθεί «*πότε ένα μοντέλο είναι πολύ περίπλοκο;*», αναρωτήθηκε «*ποιο είναι το ελάχιστο από όπου πρέπει κάποιος να ξεκινήσει;*»

Οι *πρώτες αρχές* μας φέρνουν αναπόφευκτα στην αρχαία Αθήνα, και στον **μεγαλύτερο όλων**, που διατύπωσε όλα τα προηγούμενα πρώτος, με τη μεγαλύτερη δυνατή σαφήνεια, και την τέλεια μαθηματική οικονομία των Αρχαίων Ελληνικών:

«ἡ δι' ἐλαττόνων ἄρα κρείττων, εἴπερ ὁμοίως γνώριμοι αἱ ἀρχαί.»

«Η απόδειξη διά λιγοτέρων αρχών είναι ανώτερη, εφόσον οι αρχές αυτές είναι γνωστές.»

Αριστοτέλης, *Ἀναλυτικὰ Ὕστερα*, 350 π.Χ.

Ο κόσμος είναι θορυβώδης. Το πραγματικό ερώτημα δεν είναι εάν το μοντέλο μας είναι τέλειο. Είναι εάν έχει μάθει κάτι αληθινό και χρήσιμο. Την απάντηση οι μαθηματικοί την έχουν ονομάσει **Γενίκευση**.

Ο Αριστοτέλης την είχε ονομάσει ***σοφία***.

ΕΥΧΑΡΙΣΤΙΕΣ - ΔΗΛΩΣΗ ΧΡΗΣΗΣ ΤΕΧΝΗΤΗΣ ΝΟΗΜΟΣΥΝΗΣ

- Ευχαριστώ τους καθηγητές μου για την εποικοδομητική κριτική στις πρώιμες εκδόσεις του άρθρου.
- Όλα τα διαγράμματα του παρόντος άρθρου σχεδιάστηκαν με την βοήθεια του AI agent Claude Opus 4.6 Extended (Anthropic, 2026), το οποίο συνέβαλε στην συγγραφή κώδικα Python / matplotlib για την διαμόρφωση τους, υπό τις λεπτομερείς οδηγίες του συγγραφέα.

ΠΑΡΑΡΤΗΜΑ – Μαθηματική θεμελίωση της Αντιστάθμισης Μεροληψίας - Διακύμανσης

<u>Θεώρημα:</u> $\textit{Συνολικό Σφάλμα} = \textit{Μεροληψία}^2 + \textit{Διακύμανση} + \textit{Μη Αναγώγιμος Θόρυβος}$

$$\textit{Συνολικό Σφάλμα} = \underbrace{\mathbb{E}\left[\left(\hat{y} - \bar{\hat{y}}\right)^2\right]}_{\textit{Διακύμανση}} + \underbrace{\left(\bar{\hat{y}} - f(x)\right)^2}_{\textit{Μεροληψία}^2} + \underbrace{\sigma^2}_{\textit{Μη Αναγώγιμος Θόρυβος}}$$

<u>Ορισμοί:</u> Έστω $f(x)$ η άγνωστη συνάρτηση που θέλουμε να προσεγγίσουμε και $\hat{y}$ η πρόβλεψη του μοντέλου μας.

Κάθε παρατήρηση y περιέχει μη αναγώγιμο θόρυβο ε: $y = f(x) + \varepsilon$, όπου $\mathbb{E}[\varepsilon] = 0$ επειδή ο θόρυβος είναι τυχαίος, με μέση τιμή 0, και $\mathbb{E}[\varepsilon^2] = \sigma^2$ (σταθερή διακύμανση θορύβου).

Ορίζουμε επίσης: $\bar{\hat{y}} = \mathbb{E}[\hat{y}]$, σαν την μέση πρόβλεψη του μοντέλου σε πολλά διαφορετικά σύνολα εκπαίδευσης.

<u>Απόδειξη:</u> Ξεκινάμε από τον ορισμό του Variance: $=\mathbb{E}[(\hat{y} - y)^2]$. Αντικαθιστούμε $y = f(x) + \varepsilon$: $= \mathbb{E}[(\hat{y} - f(x) - \varepsilon)^2]$. Προσθέτουμε και αφαιρούμε $\bar{\hat{y}}$ για να διαχωρίσουμε τους όρους: $= \mathbb{E}\left[\left(\left(\hat{y} - \bar{\hat{y}}\right) + \left(\bar{\hat{y}} - f(x)\right) - \varepsilon\right)^2\right]$

Θέτουμε για συντομία:
- $A = \hat{y} - \bar{\hat{y}}$: απόκλιση πρόβλεψης από την μέση της
- $B = \bar{\hat{y}} - f(x)$: μέση απόκλιση από την αληθινή τιμή
- $C = \varepsilon$: μη αναγώγιμος θόρυβος

Άρα: $\textit{Συνολικό Σφάλμα} = \mathbb{E}[(A + B - C)^2]$

Αναπτύσσουμε: $= \mathbb{E}[A^2] + \mathbb{E}[B^2] + \mathbb{E}[C^2] + 2\mathbb{E}[AB] - 2\mathbb{E}[AC] - 2\mathbb{E}[BC]$

Εφαρμόζουμε τις ιδιότητες της μαθηματικής προσδοκίας:
- $\mathbb{E}[A] = \mathbb{E}\left[\hat{y} - \bar{\hat{y}}\right] = 0$, ο όρος $2\mathbb{E}[AB]$ **μηδενίζεται**
- $\mathbb{E}[C] = \mathbb{E}[\varepsilon] = 0$, ο όρος $2\mathbb{E}[BC]$ **μηδενίζεται**
- $\mathbb{E}[AC] = \mathbb{E}\left[\left(\hat{y} - \bar{\hat{y}}\right)\varepsilon\right] = 0$ επειδή ο θόρυβος είναι ανεξάρτητος από το μοντέλο, ο όρος $2\mathbb{E}[AC]$ **μηδενίζεται**
- $O\ B^2 = \left(\bar{\hat{y}} - f(x)\right)^2$ είναι σταθερός, άρα $\mathbb{E}[B^2] = B^2$

Απομένουν τρεις όροι: $\textit{Συνολικό Σφάλμα} = \underbrace{\mathbb{E}\left[\left(\hat{y} - \bar{\hat{y}}\right)^2\right]}_{\textit{Διακύμανση}} + \underbrace{\left(\bar{\hat{y}} - f(x)\right)^2}_{\textit{Μεροληψία}^2} + \underbrace{\sigma^2}_{\textit{Μη Αναγώγιμος Θόρυβος}}$

ΒΙΒΛΙΟΓΡΑΦΙΑ

Bishop, C.M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Ghojogh, B. & Crowley, M. (2023). The Theory Behind Overfitting, Cross Validation, Regularization, Bagging, and Boosting. *arXiv:1905.12787v2*.

Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.

Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.

James, G., Witten, D., Hastie, T. & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.

Malato, G. (2021). *An example of overfitting and how to avoid it*. Your Data Teacher Blog. Retrieved April 2026, from https://www.yourdatateacher.com/2021/04/12/an-example-of-overfitting-and-how-to-avoid-it/

Stat 20 — Introduction to Probability and Statistics (2025). *Overfitting*. University of California, Berkeley. Retrieved April 2026, from https://stat20.berkeley.edu/fall-2025/5-prediction/03-overfitting/tutorial.html

Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux.

Kolmogorov, A.N. (1965). *Three approaches to the quantitative definition of information.* Problems of Information Transmission, 1(1), 1-7.

Shannon, C.E. (1948). *A Mathematical Theory of Communication. Bell System Technical Journal*, 27(3), 379–423.

Popper, K. (1959). *The Logic of Scientific Discovery*. Hutchinson.

Descartes, R. (1637). *Discours de la Méthode. Leiden: Jan Maire. Αγγλική μετάφραση: Discourse on the Method (1968). Μετάφραση F.E. Sutcliffe. London: Penguin Classics.*

Aristotle (350 BC). *Posterior Analytics*. Book I, Chapter 25, 86a.