Γιατί το MSE = 0 είναι καταστροφικό

Overfitting, ChatGPT και τα Μαθηματικά της Γενίκευσης

Δαυίδ Ράδος

Μαθητής Β' Γυμνασίου, Campion School. [0009-0000-7937-407X]. 12 Απρ 2026

Περίληψη

Γιατί η αποστήθιση παλαιών διαγωνιστικών θεμάτων δεν εγγυάται την επιτυχία στις εξετάσεις; Γιατί το ChatGPT δεν απομνημονεύει όλο το περιεχόμενο του διαδικτύου; Η απάντηση και στις δύο ερωτήσεις είναι ίδια: Overfitting (υπερπροσαρμογή), είναι η παγίδα του να προσαρμοζόμαστε σε υπάρχοντα δεδομένα με τόσο μεγάλη ακρίβεια, που έχει σαν αποτέλεσμα να χάνουμε την γενίκευση. Αυτό το άρθρο εισάγει την έννοια του overfitting μέσα από ένα παράδειγμα πρόβλεψης ημερήσιων θερμοκρασιών, αναπτύσσει τα μαθηματικά του Μέσου Τετραγωνικού Σφάλματος - MSE, του Θεωρήματος Προσαρμογής Lagrange, της μεροληψίας - Bias, της διακύμανσης – Variance, και παράλληλα συνδέει αυτές τις ιδέες με το πως τα Μεγάλα Γλωσσικά Μοντέλα – LLMs εκπαιδεύονται. Παρουσιάζονται οι ιδέες των Popper, Kolmogorov, Kahneman και Αριστοτέλη πάνω στην έννοια της *γενίκευσης*. Το άρθρο συμπεραίνει ότι ένα μαθηματικό μοντέλο που πετυχαίνει MSE=0 στο σετ δεδομένων εκπαίδευσης, δεν μαθαίνει τα υποκείμενα μοτίβα – απλώς απομνημονεύει θόρυβο.

1. Μετά το διαγώνισμα

«*Μα πως είναι δυνατόν να έγραψα τόσο άσχημα;*» Ο Πάνος δεν μπορούσε να πιστέψει ότι, παρότι είχε διαβάσει για ατελείωτες ώρες, δεν είχε γράψει καλά στο διαγώνισμα των μαθηματικών. Πριν από κάθε διαγώνισμα μαθηματικών, διαβάζει όλα τα θέματα των προηγούμενων διαγωνισμών που μπορεί να βρει, και μαθαίνει όλες τις απαντήσεις απέξω, άπταιστα. Όταν πέφτουν τα θέματα που έχει διαβάσει, είναι ασταμάτητος. Όταν όμως τα θέματα είναι έστω και λίγο διαφορετικά (που συνήθως είναι), «την πατάει».

Από την άλλη, έχουμε την συμμαθήτριά του την Ιωάννα. Διαβάζει τις μισές ώρες και ασχολείται με τις μισές ασκήσεις σε σχέση με τον Πάνο. Όμως, όταν έχει μια απορία, ψάχνει να βρει το «γιατί». Δεν μαθαίνει όλη την ύλη απέξω χωρίς να καταλαβαίνει τι διαβάζει.

Εικόνα 1: Σκυλόσπιτο. Overfitting μόνο για τον Ρεξ.

Στις προπαρασκευαστικές ασκήσεις, τα πάει καλύτερα ο Πάνος, αλλά στα κανονικά διαγωνίσματα η Ιωάννα τον ξεπερνάει. Δεν τους χωρίζει η προσπάθεια και ο κόπος που καταβάλλουν, τους χωρίζει μια έννοια που οι μαθηματικοί και οι επιστήμονες πληροφορικής ονομάζουν **overfitting**[1] (υπερπροσαρμογή) – μια από τις σημαντικότερες ιδέες της Τεχνητής Νοημοσύνης (AI).

Στην γλώσσα των μαθηματικών, ο Πάνος έχει μηδενικό σφάλμα στο σύνολο δεδομένων προετοιμασίας **(training set)**, δηλαδή στα παλιότερα θέματα, αλλά έχει υψηλό σφάλμα στο δοκιμαστικό σύνολο **(test set)**, δηλαδή στην κανονική εξέταση. Αντίθετα, η Ιωάννα τα πάει χειρότερα στο σύνολο δεδομένων προετοιμασίας, αλλά πολύ καλύτερα στο πραγματικό διαγώνισμα. Ο Πάνος έχει απομνημονεύσει, ενώ η Ιωάννα έχει **γενικεύσει.** Η πολύ σημαντική διαφορά μεταξύ των δύο προσεγγίσεων αποτελεί το κύριο θέμα αυτού του άρθρου.

Οι επόμενες ενότητες 2 έως 5 παρουσιάζουν ένα παράδειγμα με εικονικά δεδομένα ημερήσιας θερμοκρασίας, ώστε οι έννοιες που θα αναπτυχθούν στην συνέχεια να είναι πιο εύκολα κατανοητές.

2. Ημερήσιες θερμοκρασιακές μεταβολές - Τρία μοντέλα

Ας υποθέσουμε ότι ένας μετεωρολόγος μετράει την θερμοκρασία αέρα 13 φορές κατά την διάρκεια ενός 24ωρου. Ο στόχος του είναι να βρει ένα μαθηματικό μοντέλο που προσαρμόζεται καλύτερα στις

---

[1] *Στο άρθρο χρησιμοποιείται η διεθνής αγγλική ορολογία συνοδευόμενη από την ελληνική της απόδοση. Η προσέγγιση κρίθηκε απαραίτητη καθώς η θεματική περιοχή της Τεχνητής Νοημοσύνης βασίζεται εξ' ολοκλήρου στην αγγλόφωνη βιβλιογραφία.*

μετρήσεις του, ώστε στην συνέχεια να μπορέσει να υπολογίσει τιμές θερμοκρασίας σε ώρες που δεν έχει μετρήσει πρωτογενώς.

Το ζητούμενο μαθηματικό μοντέλο θα είναι ένα **πολυώνυμο[2] ν-οστού βαθμού** της εξής μορφής:

$$P_n(x) = a_n x^n + a_{n-1}x^{n-1} + a_{n-2}x^{n-2} + \cdots + a_2x^2 + a_1x + a_0 \qquad (1)^3$$

Σε αυτήν την περίπτωση, το x παρουσιάζει τα δεδομένα εισόδου (ώρες, μετρήσεις), και οι συντελεστές $a_0, a_1, \ldots, a_n$ είναι σταθερές που χρησιμοποιούνται για καλύτερη προσαρμογή στα δεδομένα. Η **Μέθοδος των Ελαχίστων Τετραγώνων - ΜΕΤ[4]** είναι η καλύτερη επιλογή αξιολόγησης του μοντέλου, αφού επιτρέπει να ελαχιστοποιήσουμε το άθροισμα των τετραγώνων των διαφορών (σφαλμάτων) μεταξύ των παρατηρούμενων τιμών και των τιμών που προβλέπονται από το μοντέλο.

Ο μετεωρολόγος δοκιμάζει τρία μαθηματικά μοντέλα, οι γραφικές παραστάσεις των οποίων παρουσιάζονται στην *Εικόνα 2*.

- Πολυώνυμο 1ου βαθμού: Μία ευθεία που δεν μπορεί να αποδώσει σωστά τις μεταβολές της θερμοκρασίας στο 24ωρο. Είναι ένα καλό παράδειγμα **underfitting** (υποπροσαρμογής), το αντίθετο του overfitting.
- Πολυώνυμο 3ου βαθμού: Μία κυβική καμπύλη (στο διάγραμμα φαίνεται τμήμα της καμπύλης S της γραφικής παράστασης των κυβικών καμπύλων), που αποδίδει τις μεταβολές στην θερμοκρασία αρκετά ικανοποιητικά.
- Πολυώνυμο 12ου βαθμού: Η γραφική παράσταση του πολυωνύμου περνάει από κάθε σημείο μέτρησης. Θα έπρεπε να είναι το πιο κατάλληλο γράφημα συνολικά, όμως δεν είναι. Παρατηρούμε έντονα καμπυλωμένες εξάρσεις μεταξύ σημείων που προβλέπουν παράλογες θερμοκρασίες όπως για παράδειγμα κοντά στην ώρα 01:00[5]. Όταν το πολυώνυμο κληθεί να προβλέψει θερμοκρασίες εκτός των ωρών μέτρησης, καταρρέει. Είναι ένα καλό παράδειγμα **overfitting**.

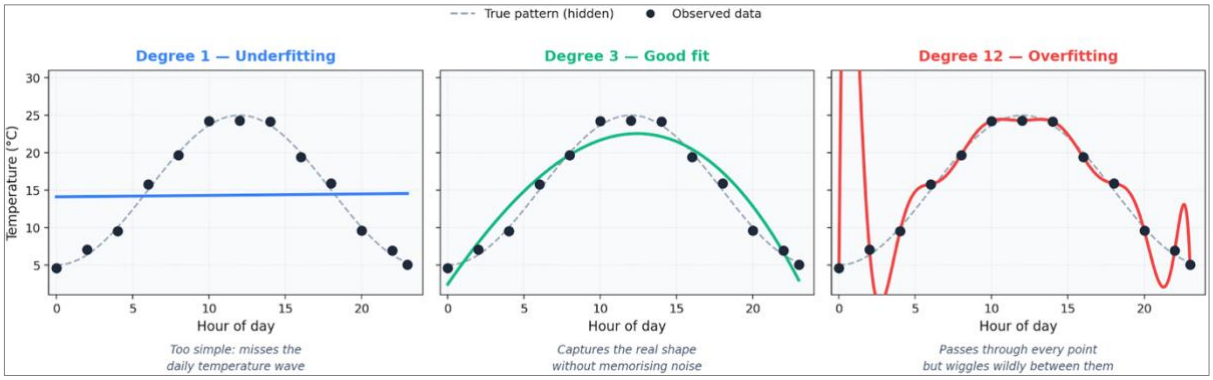

Εικόνα 2: Τρία πολυώνυμα προσαρμοσμένα στις ίδιες 13 θερμοκρασίες. Κοινά δεδομένα εισόδου, διαφορετικά αποτελέσματα[6].

[2] *Στο παρόν άρθρο οι λέξεις «μοντέλο» και «πολυώνυμο» χρησιμοποιούνται εναλλάξ και έχουν την ίδια εννοιολογική σημασία.*

[3] *Όλες οι μαθηματικές εξισώσεις του άρθρου γράφτηκαν με τον κώδικα LaTeX.*

[4] *Η ΜΕΤ επινοήθηκε ανεξάρτητα από δύο κορυφαίους μαθηματικούς στις αρχές του 19ου αιώνα, με τον Γάλλο Adrien-Marie Legendre να προηγείται στην δημοσίευση (1805), και τον Γερμανό **Carl Friedrich Gauss** να υποστηρίζει ότι την είχε αναπτύξει ήδη από το 1795, αλλά τη δημοσίευσε επίσημα το 1809 στο έργο του "Theoria motus corporum coelestium".*

[5] Τα *πολυώνυμα* Lagrange υψηλού βαθμού είναι γνωστά για τις πολύ μεγάλες εξάρσεις τους (σφάλματα), ειδικά στις άκρες του διαστήματος εφαρμογής. Ο Carl Runge ανακάλυψε αυτό το φαινόμενο (1901) μελετώντας την συνάρτηση: $f(x) = \frac{1}{1+25x^2}$ στο διάστημα [-1,1]. Το φαινόμενο Runge είναι ένα κλασικό πρόβλημα της Αριθμητικής Ανάλυσης που εμφανίζεται όταν προσπαθούμε να προσεγγίσουμε μια συνάρτηση χρησιμοποιώντας πολυωνυμική παρεμβολή υψηλού βαθμού.

[6] Όλα τα διαγράμματα του παρόντος άρθρου σχεδιάστηκαν με την βοήθεια του AI agent Claude Opus 4.6 Extended (Anthropic, 2026), το οποίο συνέβαλε στην συγγραφή κώδικα Python / matplotlib για την διαμόρφωση τις οπτικής παρουσίασης των σχημάτων, υπό τις λεπτομερείς οδηγίες του συγγραφέα.

3. Πόσο λάθος είναι το λάθος – Lagrange και MSE

Για να ποσοτικοποιήσουμε πόσο καλά το κάθε μοντέλο προσαρμόζεται στα δεδομένα, μπορούμε να χρησιμοποιήσουμε το Μέσο Τετραγωνικό Σφάλμα – ΜΤΣ, ή αλλιώς **MSE – Mean Squared Error**. Γενικότερα, για ένα σύνολο δεδομένων n, όπου το καθένα έχει μια μετρημένη τιμή y_i, και μία προβλεπόμενη από το μοντέλο $\hat{y}_i$, το MSE είναι:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \qquad (2)$$

Κάθε όρος $(y_i - \hat{y}_i)^2$ είναι το τετράγωνο υπολοίπου – της διαφοράς μεταξύ της πραγματικής μέτρησης και της πρόβλεψης (βλέπε *Εικόνα 3*).

Υπάρχουν δύο λόγοι που υψώνουμε τις διαφορές στο τετράγωνο. Ο πρώτος είναι ότι υψώνοντας στο τετράγωνο, εξαλείφουμε το πρόσημο της διαφοράς. Ο δεύτερος λόγος είναι για να δώσουμε περισσότερο βάρος σε σημεία μέτρησης που απέχουν σημαντικά από την τιμή που δίνει η εφαρμογή του πολυωνύμου. Αυτή η μέθοδος, η οποία πρακτικά «τιμωρεί» το μοντέλο, αφού η διαφορά Δy υψώνεται στο τετράγωνο, μας οδηγεί σε μία πιθανή βελτίωση του πολυωνύμου, με τους περιορισμούς που θα αναπτύξουμε στην συνέχεια. Η *Εικόνα 3* παρουσιάζει το MSE για το πολυώνυμο 3ου βαθμού.

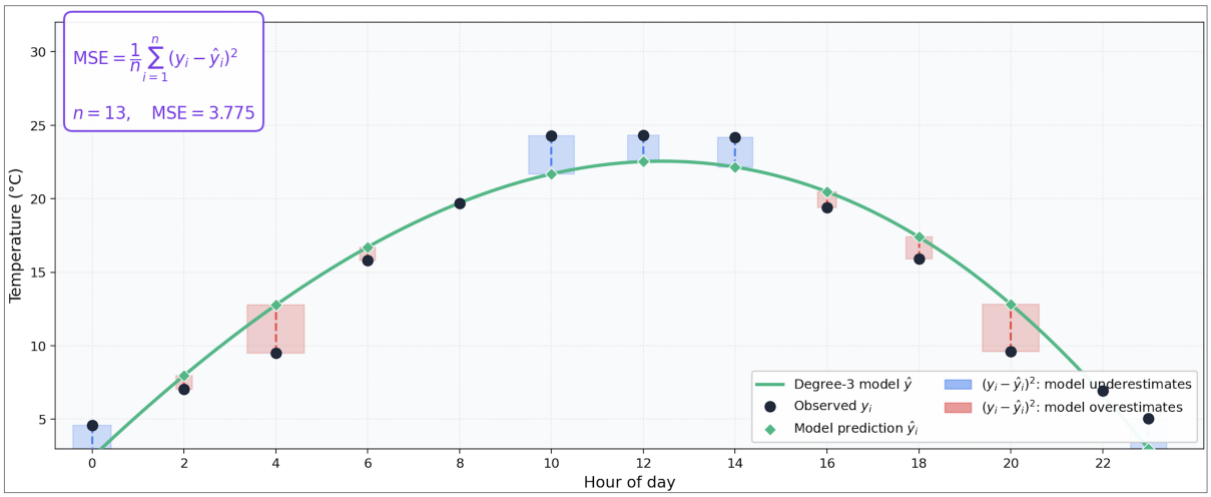

Εικόνα 3: Τετράγωνα υπολοίπων για το πολυώνυμο 3ου βαθμού. Κάθε τετράγωνο έχει εμβαδό ίσο με το τετράγωνο σφάλματος στο σημείο. Το MSE είναι ο μέσος όρος τους.

Τι συμβαίνει όμως με το πολυώνυμο 12ου βαθμού;

Όπως έχουμε προαναφέρει, το πολυώνυμο 12ου βαθμού έχει MSE = 0. Κάθε τετράγωνο υπολοίπου είναι 0. Αυτό δεν είναι σύμπτωση, είναι μαθηματική βεβαιότητα, αφού το πολυώνυμο σχεδιάστηκε για να κάνει ακριβώς αυτό.

Εικόνα 4: J.L. Lagrange (1736-1813)

Το 1795, ο Ιταλο-Γάλλος μαθηματικός Joseph-Louis Lagrange απέδειξε το **Θεώρημα Παρεμβολής Lagrange**, –ένα από τα σημαντικά θεωρήματα της Αριθμητικής Ανάλυσης– σύμφωνα με το οποίο για οποιαδήποτε σημεία δεδομένων n, υπάρχει πάντα ένα μοναδικό πολυώνυμο $n - 1$ βαθμού που περνάει ακριβώς από όλα τα σημεία. Δηλαδή που ικανοποιεί την συνθήκη: $L(x_i)=y_i$ για κάθε i=0,1,…,n.

Στο δικό μας παράδειγμα, με 13 σημεία μέτρησης, το πολυώνυμο 12ου βαθμού έχει 13 συντελεστές (έναν για κάθε σημείο) που λαμβάνουν τιμές ώστε να αφήσουν MSE = 0. Σύμφωνα με τον Lagrange, για κάθε σημείο δεδομένων i, θεωρούμε ένα **Πολυώνυμο Βάσης**[7]:

[7] Στην εξίσωση (3), ο αριθμητής είναι το γινόμενο των όρων $(x-x_0)(x-x_1)\ldots(x-x_n)$, εξαιρώντας τον όρο $(x-x_i)$. Έτσι εξασφαλίζεται ότι το πολυώνυμο θα μηδενιστεί σε όλα τα δεδομένα σημεία x_j, εκτός από το x_i. Ο παρονομαστής είναι το ίδιο ακριβώς γινόμενο με τον αριθμητή, με την διαφορά ότι στην θέση του x έχει τοποθετηθεί η σταθερή τιμή x_i. Έτσι εξασφαλίζεται ότι στο σημείο x_i το αποτέλεσμα θα είναι 1.

$$\ell_i(x) = \prod_{\substack{j=1 \\ j\neq i}}^{n} \frac{x - x_j}{x_i - x_j} \qquad (3)$$

Αυτό το πολυώνυμο, όπως εύκολα γίνεται αντιληπτό από την εξίσωση (3), έχει την εξής ιδιότητα: Εάν θέσουμε $x=x_i$, τότε $\ell_i(x_i) = 1$. Εάν θέσουμε οποιοδήποτε άλλο x_j (όπου $j \neq i$), τότε $\ell_i(x_j) = 0$.

Το τελικό πολυώνυμο παρεμβολής είναι το άθροισμα των πολυώνυμων βάσης πολλαπλασιαζόμενων με το αντίστοιχο y_i:

$$L(x) = \sum_{i=1}^{n} y_i \ell_i(x) \qquad (4)$$

Η πολυωνυμική παρεμβολή του Lagrange θα έβγαζε MSE=0 για οποιεσδήποτε 13 τιμές θερμοκρασίας, χωρίς να μπορεί να καταλάβει εάν υπάρχει κάποιο μοτίβο στα δεδομένα, απλώς λύνοντας κάθε φορά 13 εξισώσεις με 13 αγνώστους. Είναι λοιπόν κατανοητό ότι το πολυώνυμο 12ου βαθμού έχει απλώς «απομνημονεύσει» κάθε μέτρηση που του έχει δοθεί. Η αξία του στην πρόβλεψη είναι μηδενική, όπως ακριβώς και το MSE=0.

4. Εκπαιδεύοντας το μαθηματικό μοντέλο

Μέχρι τώρα είδαμε ότι στο παράδειγμα των θερμοκρασιών, τα πολυώνυμα 1ου βαθμού και 12ου βαθμού έχουν ουσιαστικά μηδενική αξία, ενώ αντιθέτως το πολυώνυμο 3ου βαθμού λειτουργεί αρκετά ικανοποιητικά. Εύλογα λοιπόν προκύπτει μια σειρά ερωτημάτων: Μήπως ένα πολυώνυμο 4ου ή 5ου βαθμού λειτουργεί καλύτερα; Ποιος βαθμός πολυωνύμου είναι αυτός που ελαχιστοποιεί το MSE, αλλά ταυτόχρονα εκπαιδεύει καλύτερα το μοντέλο;

Για να προσεγγίσουμε την απάντηση στα παραπάνω ερωτήματα, θα πρέπει να ελέγξουμε το μοντέλο με καινούργια δεδομένα που δεν έχει ξαναδεί. Για να το πετύχουμε αυτό μπορούμε να χωρίσουμε τα δεδομένα σε δύο υποσύνολα: στα δεδομένα εκπαίδευσης – **training set** και στα δεδομένα ελέγχου – **test set**. Από τις 13 μετρήσεις θερμοκρασίας που έχουμε παίρνουμε 10 από αυτές (περίπου το 80%) για να αποτελέσουν το training set, και τις υπόλοιπες 3 τις χρησιμοποιούμε για το test set.

Τώρα, μπορούμε να υπολογίσουμε δύο διαφορετικές τιμές λάθους: $MSE_{train} vs. MSE_{test}$. Η *Εικόνα 5*, παρουσιάζει τα MSE για τα δύο υποσύνολα όταν αυξάνουμε τον βαθμό του πολυωνύμου από το 1 στο 10.

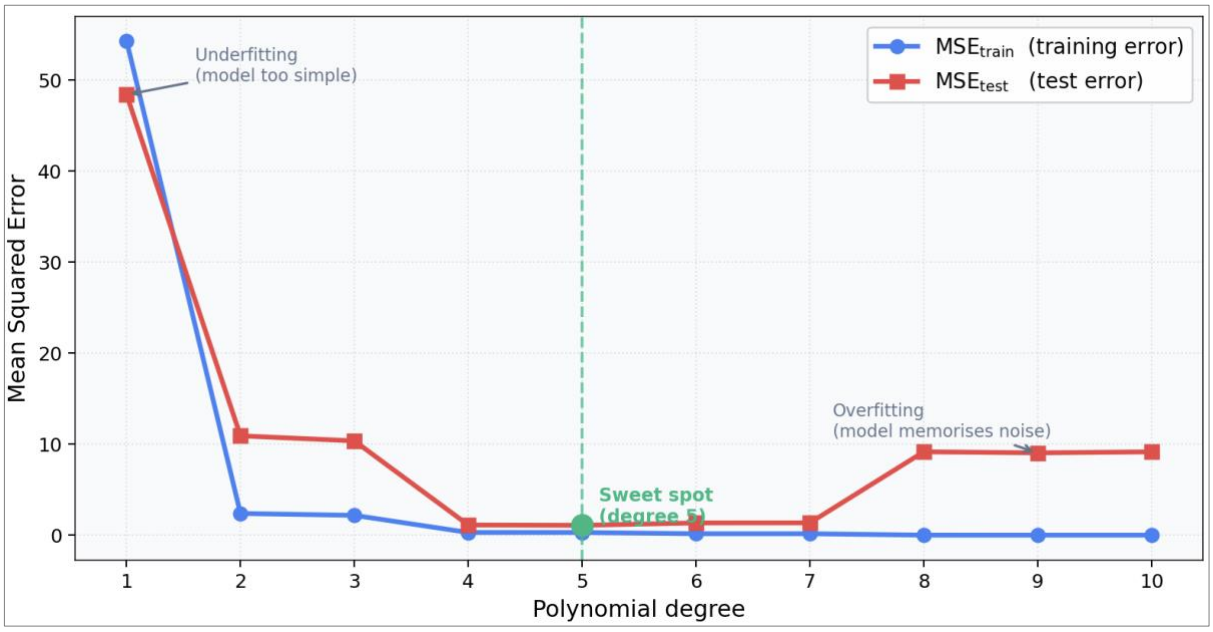

Εικόνα 5: Όσο ο βαθμός του πολυωνύμου αυξάνει, το MSE_{train} πάντα μειώνεται (μπλε). Αντιθέτως, το MSE_{test} φτάνει σε μια χαμηλή τιμή, πριν αρχίσει να ανεβαίνει.

Από την μπλε γραμμή (MSE_{train}), παρατηρούμε πως περισσότεροι παράμετροι σημαίνουν μικρότερο MSE, που στον 10ο βαθμό σχεδόν μηδενίζεται ($MSE_{train} = 0$).

Αντιθέτως, παρατηρούμε μια διαφορετική συμπεριφορά στην κόκκινη γραμμή (MSE_{test}). Σε χαμηλούς βαθμούς πολυωνύμου, το MSE_{test} είναι πολύ ψηλά. Όσο ο βαθμός όμως ανεβαίνει, το MSE_{test} πέφτει, και στον 5ο βαθμό φτάνει στο χαμηλότερο του σημείο. Στην συνέχεια όμως, όσο ανεβαίνει ο βαθμός πολυωνύμου, το MSE_{test} αρχίζει να ανεβαίνει και αυτό. Αυτή η απόκλιση είναι χαρακτηριστική του overfitting. Για παράδειγμα, για πολυώνυμα 8ου βαθμού και πάνω:

$$MSE_{train} \approx 0 \; \alpha\lambda\lambda\acute{\alpha} \; MSE_{test} \gg 0. \qquad (5)$$

Συμπερασματικά λοιπόν διαπιστώνουμε από το παράδειγμά μας ότι: Ένα μοντέλο με $MSE_{train} = 0$ έχει **απομνημονεύσει**. Ένα μοντέλο με χαμηλό MSE_{test} έχει **κατανοήσει** και δίνει αξία στην πρόβλεψη.

5. Γιατί τα μοντέλα αποτυγχάνουν: Bias και Variance

Κάθε αποτυχία ενός μαθηματικού μοντέλου μπορεί να ταξινομηθεί σε δύο κατηγορίες, οι οποίες «οδηγούν» το μοντέλο σε αντίθετες κατευθύνσεις. Αυτές είναι η Μεροληψία – **Bias** και η Διακύμανση – **Variance**.

Το **Bias** είναι το σφάλμα που προκύπτει από ένα υπεραπλουστευμένο μοντέλο. Ας γυρίσουμε πίσω στην ευθεία γραμμή πολυωνυμικού βαθμού 1 στην *Εικόνα 2*. Το μοντέλο υποθέτει ότι η θερμοκρασία μεταβάλλεται γραμμικά. Αυτή η υπόθεση είναι προφανώς λανθασμένη, και καμία ποσότητα δεδομένων δεν μπορεί να βοηθήσει στην διόρθωσή της – το μοντέλο είναι από μόνο του ανίκανο να αποδώσει την καμπυλόμορφη κατανομή των θερμοκρασιών. Συνοπτικά θα λέγαμε ότι το bias μετρά την απόκλιση μεταξύ της μέσης πρόβλεψης του μοντέλου και της πραγματικής τιμής:

$$Bias^2 = \left(\bar{\hat{y}} - y\right)^2 \qquad (6)$$

Όπου $\bar{\hat{y}}$ είναι η μέση πρόβλεψη του μοντέλου από πολλά διαφορετικά σύνολα εκπαίδευσης και y είναι η πραγματική τιμή. Ένα μοντέλο με υψηλό bias κάνει σταθερά το ίδιο λάθος. Αυτό είναι το **underfitting**.

Το **Variance** από την άλλη, είναι το αντίθετο σφάλμα. Προκύπτει από ένα πολύ «ευαίσθητο» μοντέλο, όπως για παράδειγμα το πολυώνυμο 12ου βαθμού στην *Εικόνα 2*. Το μοντέλο προσπαθεί να περάσει από κάθε σημείο, και εάν επαναλάβουμε το πείραμα μία διαφορετική ημέρα, με μικρές αλλαγές στις μετρήσεις, η ευθεία 1ου βαθμού δεν θα άλλαζε σχεδόν καθόλου, ενώ αντιθέτως, η καμπύλη 12ου βαθμού θα έμοιαζε εντελώς διαφορετική. Το variance, μετρά ακριβώς αυτή την αστάθεια:

$$Variance = \mathbb{E}\left[\left(\hat{y} - \bar{\hat{y}}\right)^2\right] \qquad (7)^8$$

Ένα μοντέλο με υψηλό variance δεν κάνει σταθερά λάθη, κάνει απρόβλεπτα λάθη. Αυτό είναι το **overfitting**.

Οι δύο τύποι σφαλμάτων συνδέονται με μια ταυτότητα, η οποία δίνει το συνολικό σφάλμα πρόβλεψης κάθε μοντέλου και αναλύεται ως εξής:

$$Total\ Error = Bias^2 + Variance + Noise \qquad (8)^9$$

Η εξίσωση (8) στην βιβλιογραφία ονομάζεται και **Bias-Variance Tradeoff**, και είναι μία από τις βασικές εξισώσεις της μηχανικής μάθησης – **machine learning**. Η γραφική απεικόνιση της εξίσωσης παρουσιάζεται στην *Εικόνα 6* στην οποία παρατηρούμε ότι:

– Όσο ο βαθμός του πολυωνύμου αυξάνει, το bias μικραίνει και τείνει να μηδενιστεί, ενώ αντίστροφα το Variance μεγαλώνει, έως ότου βγει εκτός κλίμακας.

[8] *Το σύμβολο $\mathbb{E}$ ονομάζεται **expected value** (μαθηματική προσδοκία) και εκφράζει την μέση αναμενόμενη τιμή σε πολλές επαναλήψεις σετ μετρήσεων. Με άλλα λόγια εκφράζει τον μέσο όρο των αποτελεσμάτων του μοντέλου, μετρώντας πόσο «νευρικές» είναι οι προβλέψεις του απέναντι σε μικρές διακυμάνσεις των δεδομένων.*

[9] *Το Noise αναφέρεται στον αναγώγιμο θόρυβο – **Irreducible Noise**, που είναι το σφάλμα που κανένα μοντέλο δεν μπορεί να εξαλείψει. Στο παράδειγμά μας, ακόμη και το πιο πλήρες μοντέλο αδυνατεί να προβλέψει την ακριβή θερμοκρασία, αφού για παράδειγμα η σκιά ενός σύννεφου μπορεί να την επηρεάσει απρόβλεπτα. Με άλλα λόγια είναι το κατώτατο όριο κάθε πρόβλεψης.*

– Το total error είναι καμπύλη μορφής U, όπου το κατώτατο σημείο της είναι το σημείο που καταδεικνύει τον προτιμητέο βαθμό του πολυωνύμου.

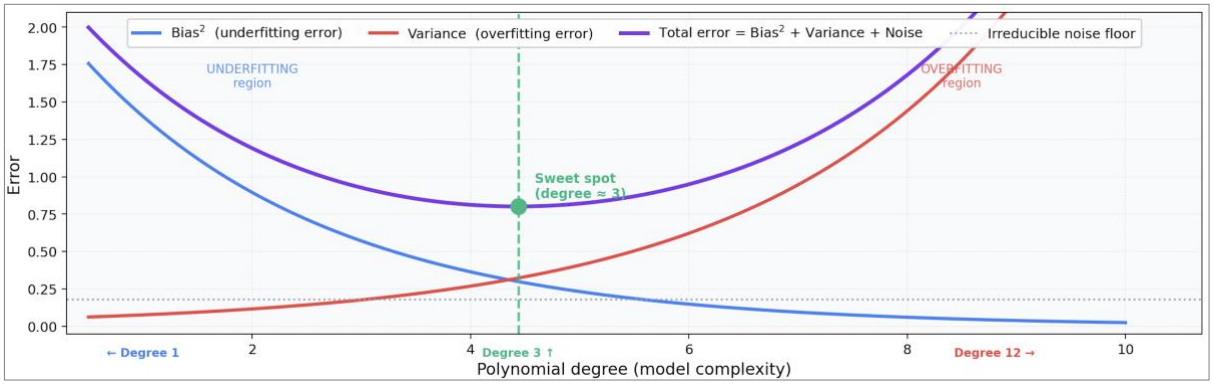

Εικόνα 6: Bias - Variance Tradeoff. Παρουσιάζονται οι δύο κατηγορίες σφαλμάτων, το συνολικό σφάλμα και το sweet spot που πρακτικά δείχνει τον ιδανικό πολυωνυμικό βαθμό του μοντέλου (βλ. σχετικά και την Εικόνα 5).

6. Το ChatGPT δεν απομνημονεύει

Το ChatGPT (v3.5) είχε περίπου 175 δισεκατομμύρια παραμέτρους. Πολύ υπεραπλουστευμένα μπορούμε να τις σκεφτούμε σαν τους συντελεστές του πολυωνύμου του παραδείγματός μας.

Επειδή το training set αποτελούνταν περίπου από 500 δισεκατομμύρια λέξεις, είναι προφανές ότι 175 δις παράμετροι δεν μπορούν να αποθηκεύσουν 500 δις λέξεις. Αυτό που μπορούν να κάνουν όμως είναι να ενσωματώσουν την στατιστική δομή της γλώσσας, όπως για παράδειγμα: ποιες λέξεις ακολουθούν μετά από κάποιες άλλες, ποιο είναι το γνωστικό περιβάλλον, και ποια είναι τα θέματα ενδιαφέροντος. Οι παράμετροι ενσωματώνουν όχι τις προτάσεις που υπάρχουν στις διάφορες πηγές του διαδικτύου, αλλά τους κανόνες που γενούν τις προτάσεις. Όπως ακριβώς και η Ιωάννα που δεν απομνημονεύει παλαιά θέματα διαγωνισμών, αλλά προσπαθεί να καταλάβει την λογική που κρύβεται από πίσω.

Παρόλα αυτά, ένα μοντέλο με 175 δις παραμέτρους υπερπροσαρμόζει. Για να λύσουν αυτό το πρόβλημα, οι μαθηματικοί και μηχανικοί του ChatGPT χρησιμοποίησαν τρία εργαλεία:

– **Regularisation** – Κανονικοποίηση. Κατά την διάρκεια της εκπαίδευσης του το μοντέλο «τιμωρείται» όχι μόνο όταν κάνει σφάλματα στις προβλέψεις, αλλά και όταν στηρίζεται πάρα πολύ σε ένα συγκεκριμένο μοτίβο. Με απλά λόγια, είναι σαν τον καθηγητή που λέει στους μαθητές του «*θα χάσετε βαθμούς εάν η απάντησή σας είναι μεγαλύτερη από μία σελίδα*.» Αυτή η προτροπή του καθηγητή υποχρεώνει τον μαθητή να βρει την ουσία της απάντησης, αντί να γράψει ότι έχει αποστηθίσει.

– **Test - Validation set**. Με το σύνολο ελέγχου - επαλήθευσης, παρακολουθείται η γενίκευση κατά την διάρκεια της εκπαίδευσης του μοντέλου. Όταν το MSE_{train} μειώνεται, και ταυτόχρονα το MSE_{test} αυξάνεται, τότε έχει αρχίσει το overfitting.

– **Early stopping**. Η εκπαίδευση του μοντέλου σταματάει όταν το MSE_{test} φτάσει στην ελάχιστη τιμή.

7. Τέσσερις μεγάλοι στοχαστές, επτά αιώνες, μία ιδέα

Τον 14ο αιώνα, ο **William του Ockham** υποστήριξε ότι «*όταν δύο εξηγήσεις ταιριάζουν εξίσου καλά στα ίδια δεδομένα, πρέπει να προτιμούμε την απλούστερη, αυτή που έχει τις λιγότερες παραδοχές*». Αυτή η ρήση είναι γνωστή σαν το **Occam's razor** (ξυράφι του Occam), το οποίο «ξυρίζει» όλες τις άχρηστες λεπτομέρειες ή παραδοχές από μία θεωρία.

Ο **Karl Popper** το 1934 υποστήριξε ότι μια καλή θεωρία δεν είναι αυτή που εξηγεί τα πάντα – είναι αυτή που **αποκλείει** κάτι. Με απλά λόγια, μια θεωρία συμβατή με κάθε παρατήρηση δεν ρισκάρει τίποτε, δεν δεσμεύεται σε τίποτε, και δεν μας διδάσκει τίποτε. Το ονόμασε **falsifiability** – διαψευσιμότητα, που σημαίνει ότι μια θεωρία αποκτά επιστημονική αξιοπιστία κάνοντας προβλέψεις, που θα πρέπει να μπορούν να αποδειχθούν λανθασμένες – εάν είναι λανθασμένες. Το πολυώνυμο 12ου

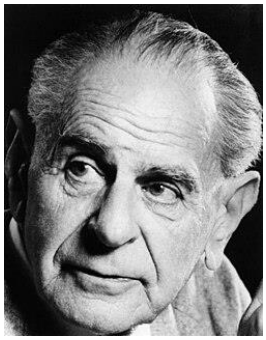

Εικόνα 7: Karl Popper (1902-1994)

βαθμού του παραδείγματός μας προσαρμόζεται πάντα και απόλυτα σε οποιουσδήποτε 13 αριθμούς από τον σχεδιασμό του. Είναι **αδιάψευστο**.

Την δεκαετία του 1960, ο μεγάλος μαθηματικός και ένας από τους θεμελιωτές της Θεωρίας της Αλγοριθμικής Πληροφορίας **Andrey Kolmogorov** έθεσε μια φαινομενικά απλή ερώτηση: «*υπάρχει αντικειμενικός τρόπος να μετρήσουμε πόσο περίπλοκο είναι ένα σύνολο δεδομένων;*» Η απάντησή του ήταν κομψή: όρισε την πολυπλοκότητα ενός συνόλου δεδομένων ως το μήκος του **συντομότερου προγράμματος** που το παράγει. Εάν το εφαρμόσουμε αυτό στο παράδειγμά μας, η ημερήσια θερμοκρασία ακολουθεί μία ημιτονοειδή μορφή που περιγράφεται από λίγες παραμέτρους. Αντίθετα για να αναπαράγουμε το πολυώνυμο 12ου βαθμού χρειαζόμαστε 13 συντελεστές, χωρίς καμία εσωτερική λογική, με υψηλή πολυπλοκότητα Kolmogorov.

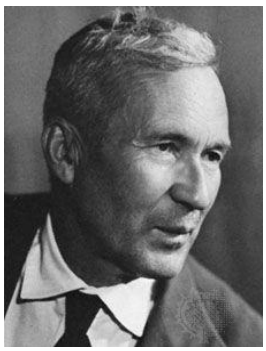

Εικόνα 8: Andrey Kolmogorov (1903-1987)

Ο ψυχολόγος και νομπελίστας οικονομικών **Daniel Kahneman** απέδειξε ότι η ανθρώπινη κρίση υποφέρει από τα ίδια προβλήματα που πραγματεύεται το άρθρο μας. Στο διάσημο βιβλίο του **Thinking Fast and Slow** (2011), διακρίνει δύο τρόπους σκέψης. Το **Σύστημα 1** (the limbic system), που είναι γρήγορο και διαισθητικό. Πρόκειται για ένα μοντέλο υψηλής διακύμανσης που υπερπροσαρμόζεται σε παραστάσεις και το αποκαλεί «ένστικτο». Το **Σύστημα 2**, (the cognitive brain) που είναι αργό, αναλυτικό και συνειδητό, και που εφαρμόζει Κανονικοποίηση, (όπως και τα μοντέλα του ChatGPT) και ρύθμιση στις αντιδράσεις του Συστήματος 1.

Είναι εύλογο να αναρωτηθούμε τι είναι αυτό που συνδέει έναν Άγγλο μοναχό του μεσαίωνα, έναν Αυστριακό φιλόσοφο, έναν Σοβιετικό μαθηματικό και έναν Ισραηλινό ψυχολόγο; Κανένας τους δεν είχε γράψει ούτε μία γραμμή από κώδικα. Κανένας τους δεν είχε εκπαιδεύσει νευρωνικά δίκτυα, και κανένας τους δεν είχε προσαρμόσει πολυώνυμα σε μετρήσεις θερμοκρασίας. Και όμως, ο καθένας δουλεύοντας στην δική του επιστήμη και στην δική του εποχή, κατέληξε στο ίδιο συμπέρασμα.

4 στοχαστές, 7 αιώνες, 1 ιδέα: **Ένα μοντέλο που εξηγεί τα πάντα δεν έχει κατανοήσει τίποτα**.

8. *αἱ ἀρχαί*

Ξεκινήσαμε με τον Πάνο και την Ιωάννα. Ο Πάνος απομνημόνευσε παλιά θέματα και είχε τέλεια βαθμολογία στο σύνολο εκπαίδευσής του. Η Ιωάννα κατανόησε το *γιατί*, έκανε περισσότερα λάθη στην εκπαίδευση, αλλά κέρδισε στο πραγματικό διαγώνισμα.

Στην συνέχεια, ο μετεωρολόγος δοκίμασε μια σειρά από μοντέλα στις μετρήσεις του. Ο Lagrange του εγγυήθηκε το *MSE=0*, αλλά το *bias* και το *variance* τον βεβαίωσαν ότι αυτό δεν είναι η λύση. Ο Ockham, ο Popper, ο Kolmogorov και ο Kahneman είπαν το ίδιο πράγμα: η τέλεια προσαρμογή στο παρελθόν δεν είναι κατανόηση – είναι η απουσία της κατανόησης.

Τα ευρήματα της εργασίας μας, μας κατευθύνουν να στηριχθούμε στις **πρώτες αρχές** – first principles. Από τις σύγχρονες επιδραστικές προσωπικότητες, ο Elon Musk έχει περιγράψει τις *πρώτες αρχές* με απλά αγγλικά: «*boiling things down to the most fundamental truths and reasoning up*».

Οι *πρώτες αρχές* μας φέρνουν αναπόφευκτα στην αρχαία Αθήνα, και στον **μεγαλύτερο όλων**, που διατύπωσε όλα τα προηγούμενα πρώτος, με τη μεγαλύτερη σαφήνεια, και την τέλεια μαθηματική οικονομία των αρχαίων Ελληνικών:

«ἡ δι' ἐλαττόνων ἄρα κρείττων, εἴπερ ὁμοίως γνώριμοι αἱ ἀρχαί.»

«Η απόδειξη διά λιγοτέρων αρχών είναι ανώτερη, εφόσον οι αρχές είναι εξίσου γνωστές.»

Αριστοτέλης, *Ἀναλυτικὰ Ὕστερα*, 350 π.Χ.

Ο κόσμος είναι θορυβώδης. Το πραγματικό ερώτημα δεν είναι εάν το μοντέλο είναι τέλειο. Είναι εάν έχει μάθει κάτι αληθινό και χρήσιμο. Οι μαθηματικοί το έχουν ονομάσει **γενίκευση**.

Ο Αριστοτέλης το είχε ονομάσει ***σοφία***._

Βιβλιογραφικές αναφορές:

[1] Aristotle (350 BC). *Posterior Analytics*. Book I, Chapter 25, 86a.
[2] Bishop, C.M. (2006). *Pattern Recognition and Machine Learning*. Springer.
[3] Ghojogh, B. & Crowley, M. (2023). The Theory Behind Overfitting, Cross Validation, Regularization, Bagging, and Boosting. *arXiv:1905.12787v2*.
[4] Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.
[5] Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
[6] James, G., Witten, D., Hastie, T. & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.
[7] Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux.
[8] Kahneman, D., Sibony, O. & Sunstein, C.R. (2021). *Noise: A Flaw in Human Judgement*. Little, Brown Spark.
[9] Kolmogorov, A.N. (1963). On tables of random numbers. *Sankhyā: The Indian Journal of Statistics*, 25(4), 369–376.
[10] Malato, G. (2021). An example of overfitting and how to avoid it.
[11] Popper, K. (1959). *The Logic of Scientific Discovery*. Hutchinson.
[12] Stat 20, University of California Berkeley (2025). Overfitting - Lecture Notes.